




機械学習

2025年11月1日 改訂版

DeepSquare AI講座 AIエンジニア育成講座（E資格講座）

アジェンダ

□ 機械学習の基礎

- ✓ パターン認識
- ✓ 機械学習の分類
- ✓ 機械学習の課題
- ✓ 検証集合
- ✓ 性能指標

パターン認識

目標

- 各距離の計算方法・性質を理解し、データの特徴に応じた距離の選択が行える。

キーワード

- k近傍法・近傍法
 - kd-tree
 - 近似最近傍探索
- 距離計算
 - コサイン距離
 - ユークリッド距離
 - マンハッタン距離
 - L_p 距離
 - マハラノビス距離

ポイント

- k近傍法・近傍法
 - k近傍法のアルゴリズムを説明できる。
 - 訓練サンプル数に比例して計算量が多くなることを説明できる。
 - kd-tree のアルゴリズムを説明できる。
- 距離計算
 - 各距離（コサイン距離・ユークリッド距離・マンハッタン距離・ L_p 距離・マハラノビス距離）が計算できる。
 - 各距離の性質を理解し、実際にそれが用いられている事例を知る。


k近傍法

k近傍法

- ・ 教師あり学習手法で、分類問題（目的変数が離散値）を扱う。
- ・ 任意のK個のデータを距離が近い順に取得し、データが属するクラスを多数決で推定する。
- ・ $k=1$ のとき、つまり最も近いデータと同じクラスに分類するのは、**最近傍法**と呼ばれる。

k近傍法の流れ

- ① 学習データを配置する。（下図では、赤群と青群。）
- ② 事前にいくつかのデータ数の投票によって分類を判定するかを決定する。（kの決定）
※kは同数投票にならないように、奇数にする。
- ③ 新たなデータを配置し、近くにあるk個のデータのなかで最も多いものと同じ分類として判定する。



k=3のとき

- ・ 赤点 2つ
 - ・ 青点 1つ
- ⇒新しいデータ点の分類は「赤」

k=5のとき

- ・ 赤点 2つ
 - ・ 青点 3つ
- ⇒新しいデータ点の分類は「青」


kd-tree

kd-tree (kd木)

- k 次元のユークリッド空間にある点を次元毎に分割する木構造。Kd-treeによってデータを分割して管理することで、最近傍法や k 近傍法を用いた探索を高速に行うことができる。

kd-treeの流れ


- まず次元（軸）を1つ選び、閾値で直交する超平面で2つに空間を分割する。
- 次に新たに次元を選び、2つに分けたデータを再度分割する。
- これを繰り返すことで、データを細かく分割する。



近似最近傍探索

近似最近傍探索

- 最近傍探索では、次元が大きくなると計算量が膨大になってしまい、限られた時間の中で正確な解を求めることが難しくなる。
- 近似最近傍探索は、近傍点との距離の近似解を求めることで計算量を減らし、計算速度を高めた探索法のこと。
- $d(q, x^*)$ を最近傍までの距離、 $d(q, x)$ を近似解までの距離として、 $d(q, x) \leq (1 + \varepsilon)d(q, x^*)$ を満たす x を近似解とする。



手順

- データを矩形領域に1つずつ属するように分割する。
- q から最も近い領域を探す。左図の場合は領域Aとの距離が最も短い。
- 次に、 x_A から順に q との距離を計算する。
 $r = \frac{d(q, x)}{1 + \varepsilon}$ 、入力データから各領域までの距離を r' として、
 $r < r'$ を満たしたとき、探索を終了する。このとき、
 $d(q, x) = (1 + \varepsilon)r \leq (1 + \varepsilon)r' \leq (1 + \varepsilon)d(q, x^*)$ を満たす。

ユークリッド距離・マンハッタン距離

様々な距離

ユークリッド距離


- 人が定規で測るような二点間の「通常の」距離のこと。
- 三平方の定理によって求められる。

max距離

- 最も距離が離れている要素の距離を評価。
- 1要素でも大きく異なる場合を評価する場合に利用。（ただし、1要素間でのみの評価になるため、全体的な差異は評価できない）

マンハッタン距離


- 座標の差の絶対値の総和で表される距離のこと。
- マンハッタンの市街地（縦横が区画整備された碁盤の目のような街）を移動する距離 のイメージ。
- 市街地距離とも呼ばれる。



Lp距離

ノルム

- **ノルム**とはいろいろなものの「大きさ」を表す量。
- 解析学においては、平面あるいは空間における幾何学的ベクトルの「長さ」の概念の一般化であり、ベクトル空間に対して「距離」を与えるための指標。
- L^p ノルムは代表的なノルムで、
 L^2 = ユークリッド距離 L^2 ノルム: $\sqrt{x_1^2 + x_2^2 + \cdots + x_n^2}$
 L^1 = マンハッタン距離 L^1 ノルム: $|x_1| + |x_2| + \cdots + |x_n|$
- L^∞ ノルムを、絶対値最大の成分の絶対値と定義する。無限大ノルム、supノルムなどとも言う。



コサイン距離

コサイン類似度

- コサイン類似度は 2本のベクトルがどれくらい同じ向きを向いているのかを表す指標のこと。
($-1 \leq \text{コサイン類似度} \leq 1$ 、最大値 1 のとき全く同じ向きを向いていることを意味する。)
- 2つのベクトルがなす角度を測っているとも考えられる。

- N次元のベクトル x, y とすると、
$$\text{Cossim}(x, y) = \frac{\sum_i x_i y_i}{\sqrt{\sum_i x_i^2} \sqrt{\sum_i y_i^2}}$$

コサイン類似度の具体的な計算


2つのベクトル a, b のなす角度 θ を考えると、

$$\text{内積 } a \cdot b = |a||b| \cos\theta \quad \text{から} \quad \text{コサイン類似度 } \cos\theta = \frac{a \cdot b}{|a||b|}$$

同じ方向を向いている時、 $\cos\theta = 1$

逆方向を向いている時、 $\cos\theta = -1$

似ていれば似ているほど、大きな値になる。(1に近づく)



コサイン距離

コサイン距離 = $1 - \text{コサイン類似度}$ 。

コサイン類似度が高いほど（つまり、ベクトルが似ているほど）、コサイン距離は小さくなる。

値は0から2の範囲になる。0は完全な類似性を、2は完全な非類似性（ベクトルが反対方向）を意味する。

マハラノビス距離

マハラノビス距離

- 分散共分散行列を利用して、データの相関関係を考慮した距離のことをマハラノビス距離という。

$$d = \sqrt{(\vec{x} - \vec{\mu})^T \Sigma^{-1} (\vec{x} - \vec{\mu})} \quad \text{※}\Sigma\text{は共分散行列} \quad \Sigma = \frac{1}{m} \sum_{i=1}^m (x_i - \mu)(x_i - \mu)^T$$


- データ内に存在するまとまりからどの程度離れているかを示しているため、**異常検知**などで用いられる。

マハラノビス距離を用いた異常検知

- 楕円を描くような形でマハラノビス距離は描かれることになる。
- 複数にわたって描くことで、異常値の閾値の大きさを示すことができる。
- 閾値が大きいと楕円が大きく、異常値の割合は少なくなる。

赤を合格ラインとすると、黄は合格だが、青は不合格（＝異常）となる。ユークリッド距離としては黄の方が遠いが、合格群との近さを測れるマハラノビス距離では青の方が遠いことがわかる。

マハラノビス距離を用いた異常検知



機械学習の分類

目標

- ・ 教師あり学習と教師なし学習の考え方を理解する。
- ・ 半教師あり学習の考え方を理解する。

キーワード

- ・ 機械学習
- ・ 教師あり学習
- ・ 教師なし学習
- ・ 半教師あり学習



ポイント

- ・ 教師あり学習・教師なし学習の特徴と、その代表的な手法についてのアルゴリズムを理解し、対象となるデータ集合とタスクに応じて、手法を選択できる。
- ・ 半教師あり学習の特徴と、その代表的な手法についてのアルゴリズムを理解し、対象となるデータ集合とタスクに応じて、手法を選択できる。

機械学習の分類


機械学習（Machine Learning）とは

- ・ 明示的にプログラムしなくても学習する能力をコンピューターに与える研究分野。（Arther Samuel, 1959）
- ・ データの集合をもとに、**データに潜む法則性を自動的に学習・発見**し、データを予測、分析すること。
- ・ コンピュータは専門的な知識を**事前に受け取ることなく**パターンを発見する。



機械学習の分類

機械学習の枠組み



機械学習の分類

機械学習の分類

機械学習は、利用できるデータによって「教師あり学習」、「教師なし学習」、「強化学習」などの学習方法を選択することになる。

教師あり学習


- ・ 「**入力**」と「**正しい出力（教師）**」が**セットになったデータ**をあらかじめ用意して、入力を与えられた時に、正しい出力ができるようにコンピュータに学習させる学習方法。

教師なし学習

- ・ **入力用のデータのみ**を与え、データに内在する構造を掴むために用いられる学習方法。データの中にある一定のパターンやルールを抽出することが目的。

強化学習

- ・ **状態・行動・報酬を入力データ**として与える。これらの対応関係をモデル化し、報酬を最大化するような行動を学習させる。



機械学習の分類

教師あり学習

教師あり学習には、主に以下の2つのタスクがあります。

回帰 (Regression)

- 連続値を予測するタスクです。たとえば、家の広さや立地条件から、家の価格を予測することが考えられます。代表的なアルゴリズムには、**線形回帰**、**リッジ (Ridge) 回帰**、**ラッソ (Lasso) 回帰**などがあります。

分類 (Classification)

- カテゴリー（離散値）を予測するタスクです。たとえば、画像データから、その画像が犬か猫かを判断することが考えられます。代表的なアルゴリズムには、**ロジスティック回帰**、**サポートベクターマシン**、**ランダムフォレスト**、**勾配ブースティング**、**ニューラルネットワーク**などがあります。

機械学習の分類

教師なし学習

教師なし学習には、主に以下の3つのタスクがあります。

クラスタリング (Clustering)

- データを類似性に基づいてグループ化するタスクです。クラスタリングによって、データの潜在的な構造やカテゴリーを見つけることができます。代表的なアルゴリズムには、**k-平均法**、**階層的クラスタリング**、**DBSCAN** などがあります。

次元削減 (Dimensionality Reduction)

- 高次元データを低次元空間にマッピングするタスクです。次元削減によって、データの可視化や冗長な情報の削除、計算コストの削減が可能になります。代表的なアルゴリズムには、**主成分分析 (PCA)**、**t-SNE**、**UMAP** などがあります。

異常検出 (Anomaly Detection)

- データセット内の異常値や外れ値を検出するタスクです。異常検出は、カード詐欺検出やシステムの故障検出など、さまざまな分野での応用が考えられます。代表的なアルゴリズムには、**One-Class SVM**、**Isolation Forest**、**Local Outlier Factor (LOF)** などがあります。

機械学習の分類

半教師あり学習


- ・ 少量の教師ありデータと、大量の教師なしデータを使って学習する方法。
- ・ 教師ありデータのみで学習する教師あり学習と教師なしデータのみで学習する教師なし学習の間に位置づけられる。
- ・ 教師ありデータが限られている場合や、ラベル付けが困難・高コストな状況で有効。
- ・ 半教師あり学習は、一般に「半教師あり分類学習」と「半教師ありクラスタリング」に分けられる。

①半教師あり分類学習（transductive learning）

- ・ 教師ありデータから分類器を作り、それを使って教師なしデータにラベルを付ける。ラベル付けには、確信度の高い分類結果を利用する。
- ・ 「ラベルプロパゲーション」や「Self-Training」と呼ばれる手法などがある。

②半教師ありクラスタリング（inductive learning）

- ・ 右図にあるようなデータ分布の場合、まず教師なしデータだけを用いて、データが2つの集団に分かれるように表現する。その後、それぞれの集団の代表点のラベル情報を使って、分類する。



左は白と黒、2つの教師データのみがある場合の教師あり学習による識別境界（点線）。右は、教師データに加え教師なしデータも加えた半教師あり学習により識別境界を得た様子。（図：Techerin、ライセンス：Creative Commons Attribution-Share Alike 3.0 Unported）

機械学習の分類

半教師あり学習で利用される仮定

- ・ ラベルのないデータを利用するためには、基礎となるデータの分布に対して関係性を仮定する必要がある。
- ・ 一般に半教師あり学習アルゴリズムは、以下の仮定のうち少なくとも一つを利用している。

①連続性の仮定

- ・ 同じラベルに該当するデータはなめらかな連続性をもっていることを仮定します。
- ・ 近いポイントにあるデータ同士は、ラベルを共有する可能性が高くなると想定できる。

②クラスターの仮定

- ・ 同じラベルに該当するデータは個別のクラスターを形成すると仮定します。
- ・ その仮定であれば、同じクラスター内のポイントは同じラベルとなる可能性が高くなると想定できる。

③多様体の仮定

- ・ データは、入力空間よりもはるかに低い次元の多様体上にほぼ存在することを仮定します。
- ・ 多様体を学習し、多様体で定義される距離と密度を使用して学習を進めます。
- ・ 多様体を直接モデル化することは難しいですが、自由度が低いプロセスで高次元データが生成される場合（声帯と声、顔の筋肉と表情など）は、実用的であると考えられる。

機械学習の課題

目標

- 機械学習特有の原理的課題を理解し、機械学習を活用した実アプリケーション開発・運用において、過剰適合・過少適合の問題の見極めおよび回避策検討ができるようになる。

キーワード

- 過剰適合・過少適合
 - 汎化誤差
 - 訓練誤差
 - バイアス
 - バリアンス
 - 正則化
 - 次元の呪い

ポイント

- 教師あり学習・教師なし学習の特徴と、その代表的な手法についてのアルゴリズムを理解し、対象となるデータ集合とタスクに応じて、手法を選択できる。
- 半教師あり学習の特徴と、その代表的な手法についてのアルゴリズムを理解し、対象となるデータ集合とタスクに応じて、手法を選択できる。

機械学習の課題

過少適合・過剰適合

過少適合（未学習、underfitting）

定義：モデルが訓練データにさえ適合できていない状態。

原因：学習不足。


影響：モデルがデータの基本的なパターンを捉えられず、未知のデータにもうまく機能しない。

過剰適合（過学習、overfitting）


定義：モデルが訓練データに過度に適合してしまう状態。

原因：訓練データの詳細まで学習しすぎる。


影響：訓練データには良い性能を示すが、未知のデータにはうまく適用できない。



過少適合



理想適合



過剰適合

機械学習の課題

汎化誤差と訓練誤差

汎化誤差（Generalization Error）

- 未知のデータに対する誤差。
- 機械学習の目的は、この汎化誤差を最小にすること。
- 過剰適合の場合、訓練データに対する誤差は小さいが、未知のデータでは大きくなる。

訓練誤差

- 訓練誤差は、機械学習モデルが訓練データにどの程度適合しているかを示す指標であり、モデルの予測と訓練データの実際の値との差（誤差）を表す。
- 訓練誤差が小さい場合、モデルが訓練データのパターンを正確に学習していることを示し、学習が進んでいることを意味する。
- ただし、訓練誤差が非常に小さい場合は、モデルが訓練データに過剰に適合している可能性があり、この状態では未知のデータに対する汎化能力が低下するリスクがある。



モデルの容量（特徴量、次元数、設定値など）を調整して、過少適合と過剰適合のバランスを取り、汎化誤差の最小化を目指していくことが必要。

機械学習の課題

汎化誤差

- 汎化誤差は、
「バイアス」（予測値と真の値の差）
「バリエーション」（モデルの分散：モデルの複雑さの度合い）
「ノイズ」（測定上避けられないズレ）
の3つの誤差に分解することができる。

バイアス・バリエーション分解：汎化誤差 = 「バイアス」 + 「バリエーション」 + 「ノイズ」

$$E(L) = \int \{y(x) - h(x)\}^2 p(x) dx + \iint \{h(x) - t\}^2 p(x, t) dx dt$$

$$= \int \{E_D[y(x; D)] - h(x)\}^2 p(x) dx + \int E_D[\{y(x; D) - E_D[y(x; D)]\}^2] p(x) dx + \iint \{h(x) - t\}^2 p(x, t) dx dt$$

バイアス


バリエーション

ノイズ

機械学習の課題

汎化誤差（バイアス、バリエーションのトレードオフ）



- モデルによる予測において、バイアス（偏り誤差）が大きすぎる場合、そのモデルは入力と出力の関係性を正確に表現できていない。そのモデルは、訓練データでさえも正確に予測できない、いわゆる「**学習不足（＝過少適合：under-fitting）**」の状態である。
- 一方、モデルの予測において、バリエーション（ばらつき誤差）が大きすぎる場合、そのモデルは訓練データのノイズまで学習してしまっている。そのモデルは、テストデータなど未知のデータでは正確に予測できない、いわゆる「**過学習（＝過剰適合：over-fitting）**」の状態である。
- バイアスとバリエーションは、基本的にトレードオフの関係性にある。そのため、モデル構築時には両者が最も低くなる適度なバランスを見つけることが重要である。



機械学習の課題

正則化

- モデルの複雑さを低減するための工夫全般を指す用語。
- 損失関数に**正則化項**（罰則項）を加えて、過剰適合を抑制する。
- スパース推定の**ラッソ回帰**（L1正則化）、縮小推定の**リッジ回帰**（L2正則化）などがある。



簡単な暗記方法

- Lassoなので、あ行1番目でL1正則化、Lが角ばっているので左図
- Ridgeなので、あ行2番目でL2正則化、Rが丸みを帯びているので右図

機械学習の課題

次元の呪い

- ・ データ量の増加などにより特徴量の数が莫大なものになると、探索のコストが時間的にも計算量的にも指数関数的に増加してしまい、適切な解を高速で見つけることが不可能になってしまう。この問題を一般に「**次元の呪い**」と呼ぶ。
- ・ このとき、データのほとんどが超球面上に分布してしまう「**球面集中現象**」が起こる。そのため、学習に際しては重要な特徴量を維持したうえで、特徴量の全体数を減らす「**特徴量選択**」や、データを低次元に変換する「**特徴量抽出**」など次元削減手法を用いる必要がある。



情報が増えれば増えるほど、爆発的に計算量が増えること。
そのため、重要な情報だけ残すようにして情報をコンパクトにする。

検証集合

目標

- ・ 訓練・検証およびテストデータの必要性と訓練集合の分割方法を理解し、適切な手法を用いて機械学習モデルを構築できる。

キーワード

- ・ 訓練データ・検証データ・テストデータ
 - ・ 訓練誤差
 - ・ 汎化誤差
- ・ 交差検証
 - ・ ホールドアウト法
 - ・ k-分割交差検証法

ポイント

- ・ 訓練誤差と汎化誤差の違いを理解し、機械学習の目的は汎化誤差を最小化するものであることを説明できる。
- ・ ホールドアウト法と k-分割交差検証法における、データセットの取り扱い方を説明できる。

検証集合

モデル評価の目的

モデルの評価は未知のデータで行う必要がある。

なぜ未知データで評価するのか？


- ・ 訓練データでは汎化性能を判断できない。
- ・ 真の性能は未知データでしか測れない。
⇒ただし、新しいデータを集めるのは困難。

解決の方向性

既存データを分割して、未知データを疑似的に作り出す。

代表的検証手法


- ・ ホールドアウト法
- ・ k-分割交差検証法
- ・ リーブワンアウト法



検証集合

基本的な流れ


1. データを訓練データ（training）、検証データ（validation）、テストデータ(test) に分ける。



検証集合

基本的な流れ

2. 訓練データで学習済みモデルを作る。




重回帰分析、ロジスティック
回帰、決定木、サポートベ
クトルマシン(SVM)、など

検証集合

基本的な流れ


3. 検証データで学習済みモデルの性能を測り、学習程度(過剰適合していないかなど)の確認やハイパーパラメータの調整を行う。



検証集合

基本的な流れ


4. 調整済みモデルを使って、テストデータで性能を試す。未知のデータ（テストデータ）に対して性能を試すことで、汎化性能を確認する。



検証集合

ホールドアウト法(Hold-Out)

- 手元のデータからテストデータを切り出し、残りの訓練データをさらに学習データと検証データに分割してモデルを構築する方法。
- 「テストデータ：学習データ：検証データ = 2 : 6 : 2」などの割合で分割することが多い。




特徴

- 計算コストが低く、サンプルサイズ（データ数）が大規模（100,000個程度）のときに適している。
- データを一度だけ分割するため、分割の仕方によってモデルの性能評価が変わりやすい。
- データ数が少ない場合、学習に使えるデータが限られ、精度が低くなるリスクがある。

検証集合

k-分割交差検証法(Cross Validation)

- ・ まずテストデータを取り出しておき、残りのデータ（訓練データ）を k 等分する。
- ・ k 回のうち、それぞれ 1 つの分割を検証データに、残りを学習データとしてモデルを学習・評価する方法。
- ・ その k 回分の検証結果を平均し、最も性能が高い（平均スコアが良い）モデルを「調整済みモデル」として、最初に取り分けておいたテストデータを用いて評価し、汎化性能を確認する。



特徴

- ・ 計算コストと精度は中程度であり、サンプルサイズ（データ数）が中規模（1,000個程度）のときに適している。
- ・ 非常に大規模なデータでは計算コストが高くなりすぎる可能性がある。一方で小規模すぎる場合、分割数を増やすほど各分割のデータ数が少なくなるため、逆にばらつきが大きくなる場合がある。

検証集合

リーブワンアウト法(Leave One Out)

- まずテストデータを取り出しておき、残りのデータ（訓練データ）から 1 つのサンプルを検証データとして分離し、残りを学習データとしてモデルを学習・評価する方法。
- データ数 N のうち、 N 回それぞれ 1 つのサンプルを検証データとし、残り $N-1$ 個を学習データとして用いる。
- N 回分の検証結果を平均し、最も性能が高い（平均スコアが良い）モデルを「調整済みモデル」として、最初に取り分けておいたテストデータを用いて評価し、汎化性能を確認する。



特徴

- すべてのデータを検証に使用できるため、データの有効活用が可能だが、ばらつきが大きくなる場合がある。
- N 回の学習と評価を行うため、計算コストが非常に高く、大規模データには不向き。

検証集合

汎化性能評価手法の使い分け

- ・ サンプルサイズ（データ数）が小さい（100個程度）ときは、計算コストは高いが精度が高くなる**リーブワンアウト法**が有効。
- ・ サンプルサイズ（データ数）が中程度（1,000個程度）のときは、計算コストはそこそこで、精度もそれなりに期待できる**k分割交差検証法**が適している。
- ・ サンプルサイズ（データ数）が大規模（100,000個程度）のときは、計算コストが小さい**ホールドアウト法**が適している。

手法	精度	計算コスト
ホールドアウト法	△	◎
k-分割交差検証法	○	○
リーブワンアウト法	◎	△

訓練データとテストデータのバランス

- ・ 訓練データを増やすと学習精度はよくなるが、性能評価精度は悪くなる。
- ・ テストデータを増やすと性能評価精度はよくなるが、学習精度は悪くなる。

性能指標

目標

- 各タスクで用いられる代表的な性能指標の特徴について理解する。

キーワード

- 正解率 (Accuracy)
- 適合率 (Precision)
- 再現率 (Recall)
- F値
- Intersection-over-Union (IoU)
- ROC曲線
- AUC
- mean Average Precision (mAP)
- 多クラス分類の評価指標 (micro平均/macro平均)
- 決定係数
- RMSE/MSE
- MAE
- 混同行列
- パープレキシティ (Perplexity)

ポイント

- 分類タスクにおける各性能指標の性質を理解し、正しく選択できる。
- 回帰タスクにおける各性能指標の性質を理解し、正しく選択できる。
- ROC曲線と PR曲線が何を表しているのか説明できる。

性能指標

性能指標とは

- 性能指標は、**モデルの良さを評価**するために用いられる。
- タスクの性質の違いから、**タスクにより用いられる性能指標が異なる**。

分類タスク

- 分類タスクでは、**正解率**（Accuracy）や**適合率**（Precision）、**再現率**（Recall）、**F値**（F-measure）、**ROC曲線**（Receiver Operating Characteristic）、**AUC**（Area Under the Curve）などが用いられる。
- 多値分類では、**micro平均**や**macro平均**により性能指標を集計して各クラスを総合した評価を行う。

回帰タスク

- 回帰タスクでは、**平均絶対誤差**（Mean Absolute Error; MAE）、**平均二乗誤差**（Mean Squared Error; MSE）、**二乗平均平方根誤差**（Root Mean Square Error; RMSE）などが用いられる。

物体検出タスク

- 物体検出タスクでは、**IoU**（Intersection over Union）、**AP**（Average Precision）、**mAP**（mean Average Precision）などが用いられる。

自然言語タスク

- 自然言語タスクでは、**BLEU**（Bilingual Evaluation Understudy）スコアや**パープレキシティ**（Perplexity）が主な性能指標として用いられる。BLEUは生成文の正解文との一致度を、パープレキシティはモデルが自然な文をどれだけ予測できるかを示す。また、要約タスクでは**ROUGEスコア**もよく使われる。

性能指標（分類タスク）

混同行列

分類モデルの性能を評価するために使われる行列で、特に二値分類や多クラス分類の結果を視覚的に表すのに便利。

		正解ラベル	
		陽 (Positive)	陰 (Negative)
予測	陽 (Positive)	TP (真陽性)	FP (偽陽性)
	陰 (Negative)	FN (偽陰性)	TN (真陰性)

TP（真陽性）

- 陽性の人を陽性と予測できた数

FP（偽陽性）

- 陰性の人を陽性と予測してしまった数

FN（偽陰性）

- 陽性の人を陰性と予測してしまった数

TN（真陰性）

- 陰性の人を陰性と予測できた数

性能指標（分類タスク）

混同行列 正解率（accuracy）

正解率 accuracy

正しく分類できたデータ数 / 全データ数
 $(TP+TN) / (TP+FN+FP+TN)$

メリット：全体の正答率をひと目で把握できる。
モデルの全体的な性能を簡単に比較できる。

デメリット：クラス（ラベル）の偏りが大きい場合、
性能を過大評価しやすい。
少数クラスの誤分類に気づきにくい。

		正解ラベル	
		陽 (Positive)	陰 (Negative)
予測	陽 (Positive)	TP (真陽性)	FP (偽陽性)
	陰 (Negative)	FN (偽陰性)	TN (真陰性)

性能指標（分類タスク）

混同行列 正解率（accuracy）

例：ある疾患検査の2クラス分類（陽性／陰性）

100人に対して検査を実施。
検査結果と実際の状況から、右図の混同行列が得られたとする。

		正解ラベル	
		陽 (Positive)	陰 (Negative)
予測	陽 (Positive)	TP = 40	FP = 5
	陰 (Negative)	FN = 10	TN = 45

正しく分類できたデータ数 / 全データ数

$(TP+TN) / (TP+FN+FP+TN)$

$$= \frac{40+45}{40+10+5+45} = \frac{85}{100} = 0.85 \text{ (85\%)}$$

分析データが不均衡な場合、性能を正しく評価できない。（例：陽性のデータが90%を占めていた場合、すべての予測を陽としても（適当に予測しても）正解率が90%になってしまう。）

Accuracyだけではなく、Recall（再現率）やPrecision（適合率）なども合わせて評価すべきである。

性能指標（分類タスク）

混同行列 適合率と再現率

適合率 precision

- 正しく予測できたデータ数 / 正しいと予測したデータ数
 $TP / (TP + FP)$

メリット：誤検知（誤って陽性と予測すること）を少なくしたい場合に利用できる。

デメリット：適合率をあげると、真に陽性（正例）なものを見逃す確率が高くなる。

再現率とトレードオフの関係にある。

		正解ラベル	
		陽 (Positive)	陰 (Negative)
予測	陽 (Positive)	TP (真陽性)	FP (偽陽性)
	陰 (Negative)	FN (偽陰性)	TN (真陰性)

再現率（真陽性率） recall

- 正しく予測できたデータ数 / 正解ラベルが陽性のデータ数
 $TP / (TP + FN)$

メリット：陽性を見逃す確率が低くなる。

デメリット：再現率を上げると、誤検知（誤って陽性だと予測すること）してしまう確率が高くなる。

適合率とトレードオフの関係にある。

		正解ラベル	
		陽 (Positive)	陰 (Negative)
予測	陽 (Positive)	TP (真陽性)	FP (偽陽性)
	陰 (Negative)	FN (偽陰性)	TN (真陰性)

性能指標（分類タスク）

混同行列 適合率と再現率

例：ある疾患検査の2クラス分類（陽性／陰性）

100人に対して検査を実施。
検査結果と実際の状況から、右図の混同行列が得られたとする。

		正解ラベル	
		陽 (Positive)	陰 (Negative)
予測	陽 (Positive)	TP = 40	FP = 5
	陰 (Negative)	FN = 10	TN = 45

適合率 precision

正しく予測できたデータ数／正しいと予測したデータ数

$$TP / (TP + FP)$$

$$= \frac{40}{40+5} = \frac{40}{45} = 0.89(89\%)$$

再現率（真陽性率） recall

正しく予測できたデータ数／正解ラベルが陽性のデータ数

$$TP / (TP + FN)$$

$$= \frac{40}{40+10} = \frac{40}{50} = 0.80(80\%)$$

この例では適合率が89%、再現率が80%となっている。つまり“陽性と予測したときの正確さ”は高い一方で、“実際の陽性をどれだけ見逃さなかったか”はやや低め。そのため、見逃しに課題がある予測であると言える。

性能指標（分類タスク）

混同行列 F 値（F-measure）

適合率(=precision)と再現率(=recall)の調和平均。

$$\begin{aligned} F &= \frac{2}{\frac{1}{Precision} + \frac{1}{Recall}} = \frac{2(Precision \times Recall)}{Recall + Precision} = \frac{2 \frac{TP^2}{(TP+FP)(TP+FN)}}{\frac{TP}{TP+FN} + \frac{TP}{TP+FP}} \\ &= \frac{2TP}{2TP + FP + FN} = \frac{TP}{TP + \frac{1}{2}(FP + FN)} \end{aligned}$$

メリット： 適合率と再現率の調和平均で計算されるため、性能をバランスよく判断できる。

デメリット： 分子がTPだけのため、陽性と陰性を対称に扱っていない。そのため、陰性と陽性を入れ替えると評価が変わることがある。

		正解ラベル	
		陽	陰
予測	陽	TP (真陽性)	FP (偽陽性)
	陰	FN (偽陰性)	TN (真陰性)

性能指標（分類タスク）

混同行列 F 値（F-measure）

例：スパムメール判定モデルのF値を計算

あるメール受信箱に届いた100通のメールを対象に、スパム判定モデルを用いて「スパム」 or 「非スパム」と自動分類させた。実際には、スパムメールが25通、非スパムメールが75通含まれていた。

		正解ラベル	
		陽 (Positive)	陰 (Negative)
予測	陽 (Positive)	TP = 20	FP = 10
	陰 (Negative)	FN = 5	TN = 65

TP（真陽性）：スパムのメールを「スパム」と判定できた数

FP（偽陽性）：非スパムのメールを「スパム」と誤判定してしまった数

FN（偽陰性）：スパムのメールを「非スパム」と見逃してしまった数

TN（真陰性）：非スパムのメールを「非スパム」と正しく判定できた数

$$F = \frac{2}{\frac{1}{Precision} + \frac{1}{Recall}} = \frac{2TP}{2TP + FP + FN} = \frac{40}{40+10+5} = \frac{40}{55} \approx 0.727(72.7\%)$$

→ 適合率と再現率の両指標を同時に評価することが可能。

性能指標（分類タスク）

混同行列 偽陽性率（False positive rate）

偽陽性率

陽性と誤って予測したデータ数／実際に陰性だったデータ数
 $FP / (FP + TN)$

メリット： 誤検知（偽陽性）の発生率を把握できる。
監視・異常検知などで誤報を抑える指標になる。

デメリット： 真陽性（正しく検知）をどれだけ見逃しているかは分からない。
適合率・再現率とのバランスを考慮する必要がある。

		正解ラベル	
		陽 (Positive)	陰 (Negative)
予測	陽 (Positive)	TP (真陽性)	FP (偽陽性)
	陰 (Negative)	FN (偽陰性)	TN (真陰性)

性能指標（分類タスク）

混同行列 偽陽性率（False positive rate）

例：ある疾患検査の2クラス分類（陽性／陰性）

200人に対して検査を実施。実際の陽性者は80人、陰性者は120人。
検査結果と実際の状況から、右図の混同行列が得られたとする。

		正解ラベル	
		陽 (Positive)	陰 (Negative)
予測	陽 (Positive)	TP = 60	FP = 15
	陰 (Negative)	FN = 20	TN = 105

誤って陽性と予測したデータ数 / 正解ラベルが陰性であるデータ数

$$\text{FP} / (\text{FP} + \text{TN}) = \frac{15}{15+105} = \frac{15}{120} = 0.125 \text{ (12.5\%)}$$


この検査では、陰性者(120人)のうち12.5%を誤って陽性と判定してしまっている。

偽陽性率が低ければ「陰性を正しく陰性と判断する力」が強いことを意味するが、反対に偽陽性率が高いほど「陰性の人を誤って陽性にしてしまう」リスクが高い。

性能指標（分類タスク）

TPR（真陽性率） と FPR（偽陽性率）

- Negative Class と Positive Class に対して、混同行列の結果があるとする。
- 判定閾値を左右に動かすことで、TPRとFPRの値が変化する。



TPR（True Positive Rate, 真陽性率） = 再現率

実際に陽性の中で正しく陽性と判定された割合。
高い方が望ましい。

$$\text{TPR} = \frac{\text{TP (真陽性)}}{\text{FN (偽陰性)} + \text{TP (真陽性)}}$$

FPR（False Positive Rate, 偽陽性率）

実際は陰性なのに陽性と誤判定された割合。
低い方が望ましい。

$$\text{FPR} = \frac{\text{FP (偽陽性)}}{\text{TN (真陰性)} + \text{FP (偽陽性)}}$$

性能指標（分類タスク）


ROC曲線

- ROC曲線とは、2値分類モデルの性能を評価するための可視化手法のひとつ。
- モデルの分類のしきい値（閾値）を変化させたときのTPRとFPRの関係を表す曲線。

縦軸：TPR（True Positive Rate, 再現率）

横軸：FPR（False Positive Rate, 偽陽性率）

真陽性率
(TPR)




偽陽性率 (FPR)

- ROC曲線が左上に近いほど性能が良いモデル（TPRが高く、FPRが低い）。
- ROC曲線の下を面積を**AUC（Area Under the Curve）**と呼ぶ。
 - AUC = 1：完璧なモデル
 - AUC = 0.5：ランダムな分類（無意味）

性能指標（分類タスク）

PR曲線（Precision-Recall）

- 分類モデルの性能を評価するための指標。
- 分類器の閾値を変更し、それに基づいて計算される **Recall**（再現率）、**Precision**（適合率）を用いた評価を行う。
- ROC曲線は偽陽性の数がそれほど重要でない場合に有用であるが、偽陽性の数が特に重要である場合、たとえば正例が少ないデータセットでは、Recall と Precision のバランスを適切に評価することが不可欠であるため、PR曲線がより適切な評価指標となることが多い。



参考 : [https://techblog.gmo-](https://techblog.gmo-ap.jp/2018/12/14/%E6%A9%9F%E6%A2%B0%E5%AD%A6%E7%BF%92%E3%81%AE%E8%A9%95%E4%BE%A1%E6%8C%87%E6%A8%99-roc%E6%9B%B2%E7%B7%9A%E3%81%A8auc/)

性能指標（分類タスク）

多クラス分類の評価指標

Macro平均

クラス単位で見る

- 各クラスに対する性能指標（例えば、適合率 や 再現率）を個別に計算し、その後でこれらの平均を取る方法。
- 各クラスを等しく重視するため、サンプル数が少ないクラスも評価に等しく寄与する。
- すべてのクラスが同様に重要な場合や、少数クラスに対しても平等な重みを与えたい場合に特に有効。

Micro平均

データ単位で見る

- 全クラスを通じての真陽性、偽陽性、真陰性、偽陰性の合計を用いて、性能指標を計算する方法。
- 各サンプル（またはインスタンス）が等しく評価に寄与する。
- クラス間でサンプル数が不均衡な場合、特にサンプル数が多いクラスの影響が大きくなるため、全体的な性能を評価するのに適している。

性能指標（回帰タスク）

回帰問題の評価指標

N : データの個数
 y_i : 真の値
 $\hat{y}_i$: 予測値

MAE

Mean Absolute Error
平均絶対誤差

- 真の値と予測値との差の絶対値の平均を取る。
- 誤差を二乗していないので、RMSEに比べて外れ値の影響を受けにくい特徴がある。

$$\text{MAE} = \frac{1}{N} \sum_{i=1}^N |y_i - \hat{y}_i|$$

MSE

Mean Squared Error
平均二乗誤差

- 真の値と予測値との差を二乗した平均を取る。
- 外れ値の影響を受けやすいため、大きな誤差を許容できないケースに使用される。
- 二乗を取るため、単位が元のデータと異なり、直感的な理解がしづらいという欠点がある。

$$\text{MSE} = \frac{1}{N} \sum_{i=1}^N (y_i - \hat{y}_i)^2$$

RMSE

Root Mean Squared Error
二乗平均平方根誤差

- 真の値と予測値との差を二乗した総和の平均値のルートを取る。
- 回帰モデルの最も一般的な性能評価指標。
- 外れ値の影響を受けやすいため、大きな誤差を許容できないケースに使用される。
- 平方根を取ることで、単位が元のデータと同じになり、誤差の大きさを直感的に把握しやすい。

$$\text{RMSE} = \sqrt{\frac{1}{N} \sum_{i=1}^N (y_i - \hat{y}_i)^2}$$

性能指標（回帰タスク）

決定係数（ R^2 ）

- 目的変数の変動（SST: Total Sum of Squares）のうち、回帰モデルによって説明可能な割合を表す指標。
- $1 - \text{SSE} / \text{SST}$ （SSE: Error Sum of Squares）で計算される。
- SSE は予測モデルの予測値と真の値との差の平方和を表す。
- 一般に、訓練データに対する決定係数は 0 から 1 までの値を取るが、テストデータでは特定の条件下において、負の値を取ることがある（モデルがデータの傾向やパターンをほとんど捉えられず、実際のデータと大幅に乖離している場合など）。

誤差平方和 (Sum of Squared Errors : SSE)

予測値と真の値との差の平方和で、予測の誤差を表す。

$$SSE = \sum_{i=1}^N \left(y_i - \hat{y}_i \right)^2$$

N : データの個数 y_i : 真の値 $\hat{y}_i$: 予測値

総平方和 (Sum of Squared Total : SST)

真の値とその平均値との差の平方和で、データセット全体の変動性を表す。


$$SST = \sum_{i=1}^N \left(y_i - \bar{y} \right)^2$$

N : データの個数 y_i : 真の値 $\bar{y}$: 平均値

性能指標（物体検出タスク）

IoU（Intersection over Union）

- 物体検出タスクでは、**検出対象を囲む長方形領域を「バウンディングボックス（Bounding Box）」**と呼ぶ。
- **IoUは、検出結果のバウンディングボックスと正解のバウンディングボックスがどの程度重なっているかを示す指標。**
- 値は0～1の範囲を取り、0は重なりがない状態、1は完全に一致している状態を意味する。
- 集合論ではJaccard係数として定義される。

$$\text{IoU} = \frac{\text{Area of Overlap (積集合)}}{\text{Area of Union (和集合)}}$$


性能指標（物体検出タスク）

IoU（Intersection over Union）を用いた精度評価

例：ボックスの座標設定

■ 正解（Ground Truth）のバウンディングボックス（赤色）

左下座標 $(x1, y1) = (50, 70)$

右上座標 $(x2, y2) = (100, 120)$

幅: $100 - 50 = 50$

高さ: $120 - 70 = 50$

面積: $50 \times 50 = 2500$

■ 予測（Prediction）のバウンディングボックス（青色）


左下座標 $(x1', y1') = (70, 50)$

右上座標 $(x2', y2') = (120, 100)$

幅: $120 - 70 = 50$

高さ: $100 - 50 = 50$

面積: $50 \times 50 = 2500$



性能指標（物体検出タスク）

IoU（Intersection over Union）を用いた精度評価

■ 積集合（overlap）の面積（黄色）

x方向の重なり区間

$$\begin{aligned} & [\max(x_1, x_1'), \min(x_2, x_2')] \\ &= [\max(50, 70), \min(100, 120)] = [70, 100] \\ &\Rightarrow \text{幅: } 100 - 70 = 30 \end{aligned}$$

y方向の重なり区間


$$\begin{aligned} & [\max(y_1, y_1'), \min(y_2, y_2')] \\ &= [\max(70, 50), \min(120, 100)] = [70, 100] \\ &\Rightarrow \text{高さ: } 100 - 70 = 30 \end{aligned}$$

→重なり部分(Overlap)の面積は $30 \times 30 = 900$

■ 和集合（union）の面積

「各ボックスの面積の合計」から「重複している面積」を引いた値

$$\begin{aligned} \text{Union} &= \text{Area}(\text{GT}) + \text{Area}(\text{Prediction}) - \text{Area}(\text{Overlap}) \\ &= 2500 + 2500 - 900 \\ &= 4100 \end{aligned}$$



○ 与えられた値

正解（Ground Truth）ボックスの面積：2500

予測（Prediction）ボックスの面積：2500

重なり（Overlap）の面積：900

和集合（Union）の面積： $2500 + 2500 - 900 = 4100$

$$\text{IoU} = 900 / 4100 = 0.2195\cdots \div 0.22$$

性能指標（物体検出タスク）

精度指標

AP(Average Precision、平均適合率)

- モデルがどの程度正確に物体を検出できているのかを示す指標。
- PR曲線に対して積分することで求められる。（0～1の範囲をとる。）

mAP(mean Average Precision、平均適合率)


- 各クラス単位で算出されたAPに対して更に平均を取った値。

性能指標（物体検出タスク）

APを計算する

- 結果のRecallを横軸、Precisionを縦軸にとり、Precision-Recall曲線を描く。
- Recallが増加するにつれて、Precisionは非単調な変動を示す場合がある。
- APは、このPrecision-Recall曲線の下面積を表し、0から1の間の値をとる。

$$AP = \int_0^1 p(r)dr$$




性能指標（物体検出タスク）

APを計算する

- Recall が $r_1, r_2, \dots, r_N$ 、Precision が $P(r_1), P(r_2), \dots, P(r_N)$ としたとき、補完後の PR 曲線の下側の面積を以下のように求めることができる。

$$AP = \sum_{i=2}^N (r_i - r_{i-1}) P(r_i)$$



性能指標（物体検出タスク）

APを計算する

- クラスが3つの場合、Label = ["class A", "class B", "class C"]の3つ全てのクラスラベルのAPを以下のように算出できる。

$$AP = \sum_{i=2}^N (r_i - r_{i-1}) P(r_i)$$

$$AP_{class\ A} = 0.753$$

$$AP_{class\ B} = 0.990$$

$$AP_{class\ C} = 0.683$$

mAPを計算する

- mAPは、すべてのクラスラベルのAPの平均を取る。（例は、クラスが3つの場合）

$$mAP = \frac{1}{C} \sum_{i=1}^C AP_i$$

$$mAP = \frac{1}{3} * (0.753 + 0.990 + 0.683) = 0.8086$$

性能指標（自然言語タスク）

BLEU（Bilingual Evaluation Understudy）

- 機械翻訳とプロの翻訳がよく似ていればいるほど、その機械翻訳の性能は高いとみなせる、という発想の指標。
- 値が0に近いほど品質が低く、1に近いほど品質が高いことを意味する。一方、「意味の正しさまでは評価できない点が課題。

$$BLEU = BP \cdot \exp\left(\sum_{n=1}^N w_n \log p_n\right)$$

w_n : 各nグラムごとの重み。
 $\log p_n$: nグラム適合率の対数 (log)

BP（Brevity Penalty）

- BPは、生成された翻訳仮説が短すぎる場合に、指数関数的な減衰を使ってスコアにペナルティを課す項。
※短い翻訳仮説のスコアが高くなってしまいうことを防ぐため。

$$BP = \begin{cases} 1 & (c > r) \\ e^{(1-\frac{r}{c})} & (c \leq r) \end{cases}$$

c : 翻訳仮説（生成文）の長さ
 r : 参照訳の長さ

nグラム適合率（n-gram : 連続するn個の単語の並び。n=1なら単語、n=2なら2語句、など）

$$p_n = \frac{\sum_i \text{翻訳仮説}i \text{ と参照訳}i \text{ で一致した}n\text{グラム数}}{\sum_i \text{翻訳仮説 中の全}n\text{グラム数}}$$

性能指標（自然言語タスク）

パープレキシティ (Perplexity)

- パープレキシティは、言語モデルの予測性能を評価するための指標であり、モデルが次に出現する単語をどれだけ正確に予測できるかを示す指標である。数値が低いほど、モデルは正解の単語を高い確率で予測していると判断される。
- 一般的に、パープレキシティが低いほど予測性能が高い。

$$\text{Perplexity} = \exp \left(-\frac{1}{N} \sum_{n=1}^N \log(p(\text{正解単語}_n)) \right)$$

N : データセット内の単語数。

$p(\text{正解単語}_n)$: n 番目の単語に対する、モデルの予測確率。

- 単語1個に対しては、パープレキシティは正解単語の予測確率の逆数、すなわち $\exp(-\log(p)) = 1/p$ となる。（たとえば予測確率が100%であれば1、10%であれば10。）
- パープレキシティは、モデルが次の単語をいくつかの選択肢の中から選んでいるかを示す指標とも解釈できる。値が低い場合はモデルが自信を持って一意に予測していることを示し、高い場合は多くの選択肢から迷って予測していることを示す。
- また、パープレキシティはクロスエントロピー誤差の指数関数としても表され、誤差が大きいほどパープレキシティの値も大きくなる。すなわち、モデルの誤差が小さく（正解単語を高い確率で予測している）、予測性能が高い場合にはパープレキシティは低くなる。

性能指標（自然言語タスク）

ROUGEスコア

- 要約タスクや自動生成文の評価で広く使われる指標。
- **生成文と参照文にどれだけ同じ語句やフレーズが含まれるか（n-gramの重複）** を評価。
- 高いROUGEスコアは「参照文によく似た要約や文章が生成できている」ことを示す

代表的なROUGEの種類

ROUGE-N :

n-gram（一続きのn単語）の一致率
（例：ROUGE-1は単語一致、ROUGE-2は2連語一致）

ROUGE-L :

最長共通部分列（LCS, Longest Common Subsequence）の長さを使った評価

計算例（ROUGE-1 Recall）

$$\text{ROUGE-1 再現率} = \frac{\text{参照文の単語のうち、生成文にも現れた数}}{\text{参照文の単語数}}$$