

修了試験A-1

合計点 53/60 点 ?

合格点 85%以上 (51以上/60)

0 / 0 ポイント

本修了試験は、本講座を受講された方を対象としています。以下の内容を確認い^{*}
ただき、該当箇所に☑を記入してください。

☒ 私は本講座を全て受講したので、各修了試験（A-1～B-8）を受験いたします。

受験者情報の登録

登録メールアドレス^{*}htanaka@777.so-net.jp御名前^{*}田中 秀伯

修了試験問題

53 / 60 ポイント



✓ 確率モデルにおけるパラメータ推定に利用される指標の説明について、 *1/1
以下のうち正しい選択肢を1つ選べ。

- ☐ ナイーブベイズは特徴量間の独立性を持たず、パラメータ調整を必要とする。
- ☐ 平均絶対誤差を最小にするパラメータを求める手法として、最小二乗法がある。
- ☒ 対数尤度は、尤度の対数を取ったものであり、尤度はパラメータの値の尤もらしさを表す。 ✓
- ☐ ダイバージェンスは、確率分布間の差異を測定するための指標であり、二つの確率分布が完全に一致する場合、その値は1になる。

✗ MAP推定（Maximum A Posteriori Estimation）とベイズ推定（Bayesian Estimation）はパラメータ推定の基本的な手法である。それぞれの手法の特徴について、以下のうちから適切なものを1つ選べ。 *0/1

- ☐ MAP推定では、最大化するのは事後確率ではなく尤度であり、事前確率はモデルの複雑さを制御するためだけに用いられる。
- ☐ ベイズ推定はパラメータの事後確率分布全体を考慮しながら局所的な確率分布を計算することで、パラメータの不確実性を評価する。
- ☒ ベイズ推定においては、個々のパラメータ値の確率を直接計算するのではなく、全ての可能なパラメータ値にわたる確率分布（事前分布）を用いて統計的な推論を行う。 ✗
- ☐ MAP推定は、観測データと事前確率を考慮し、事後確率を最大化するパラメータを求める手法である。これにより、パラメータの最も確からしい値を推定する。

- ✓ 事象Aと事象Bという二つの異なる事象を考えると、事象Aが発生する確率は $P(A)$ 、事象Bが発生する確率は $P(B)$ であり、これら二つの事象は独立である。 *1/1

また、事象Aが発生した下で事象Bが発生する確率は $P(B|A)$ 、事象Bが発生した下で事象Aが発生する確率は $P(A|B)$ と表される。 $P(B|A)$ 、 $P(A|B)$ はそれぞれ条件付き確率である。この場合における同時確率を示す式について、以下のうち正しい選択肢を1つ選べ。

- ☐ $P(B|A) \times P(A) = P(B|A) \times P(B)$
- ☐ $P(B|A) \times P(B) = P(A|B) \times P(A)$
- ☒ $P(A|B) \times P(B) = P(B|A) \times P(A)$
- ☐ $P(A|B) \times P(A) = P(A|B) \times P(B)$



- ✓ 観測データ x とパラメータ θ の確率モデルを考えた場合、MAP推定の式 *1/1 について、以下のうち正しい選択肢を1つ選べ。

$$\theta_{MAP} = \operatorname{argmax}_{\theta} p(x|\theta)$$

☐ A

$$\begin{aligned}\theta_{MAP} \\ &= \operatorname{argmax}_{\theta} \{ \log p(x|\theta) \\ &\quad + \log p(\theta) \}\end{aligned}$$

☒ B



$$\theta_{MAP} = \operatorname{argmax}_{\theta} \log p(\theta|x)$$

☐ C

$$\begin{aligned}\theta_{MAP} \\ &= \operatorname{argmax}_{\theta} \{ \log p(\theta|x) \\ &\quad + \log p(x) \}\end{aligned}$$

☐ D

標本の特徴から、そのモデルの尤もらしさを推定する必要がある。その度合いを（ あ ）といい、（ あ ）を最大化するような平均と分散を求める方法を（ い ）という。



✓ 空欄（ あ ）に当てはまる語句を以下のうちから1つ選べ。 *

1/1

- ☐ 期待値
- ☐ スパース
- ☒ 尤度
- ☐ 分散



✓ 空欄（ い ）に当てはまる語句を以下のうちから1つ選べ。 *

1/1

- ☐ スパース推定
- ☐ 区間推定
- ☐ 点推定
- ☒ 最尤推定



日本で送受信されるすべてのメールは、そのうち2%がスパムメールである。また、スパムメールのうち80%には、「出会い」という言葉が含まれていることが知られている。また、スパムメールでないメールでも、5%には「出会い」という単語が含まれていることが知られている。

今、あるメールXを受信したところ、文中に「出会い」という言葉が含まれていた。このとき、このメールがスパムメールである確率を計算したい。まず、事象Aを「スパムメールである」、事象Bを「出会い」という単語が含まれているとしておく。このとき、求めたい確率は（ あ ）である。またベイズ定理の式に当てはめると以下のように示すことができる。さらに、上記の式を適用すると、Xがスパムメールである確率は（ い ）である。

$$\frac{P(A)P(B|A)}{P(B)}$$

✓ 空欄（ あ ）に当てはまる選択肢を以下のうちから1つ選べ。 *

1/1

- ☐ P(B|A)
- ☒ P(A|B)
- ☐ P(A∩B)
- ☐ P(A∪B)



✓ 空欄（ い ）に当てはまる値を以下のうちから1つ選べ。 *

1/1

- ☐ 0.182
- ☐ 0.273
- ☐ 0.140
- ☒ 0.246



✓ エントロピー $H(X)$ と条件付きエントロピー $H(X|Y)$ の差 $H(X)-H(X|Y)$ *1/1
と等しくなるものを以下の選択肢から1つ選べ。

- ☐ エントロピー $H(X)$
- ☐ 結合エントロピー $H(X,Y)$
- ☒ 相互情報量 $I(X;Y)$
- ☐ 条件付きエントロピーの式： $H(Y|X)$



✓ 結合エントロピー $H(X,Y)$ の式として正しいものを以下の選択肢から1つ *1/1
 選べ。

$$H(X,Y) = \sum_x \sum_y P(x,y) \log_2 P(x,y)$$

☐ A

$$H(X,Y) = -\sum_x \sum_y P(x,y) \log_2 P(x,y)$$

☒ B



$$H(X,Y) = \sum_x \sum_y P(x,y) \log_2 \frac{P(x,y)}{P(x)P(y)}$$

☐ C

$$H(X,Y) = -\sum_x \sum_y P(x,y) \log_2 \frac{P(x,y)}{P(x)P(y)}$$

☐ D

k次元のワンホットベクトルで構成されるデータがマルチヌーイ分布に従っていると仮定する。また、 x_i の第j成分を x_{ij} と書くことにする。ただし、以下の式で示す性質を満たすとする。このとき、尤度関数は（ あ ）であり、負の対数尤度関数は（ い ）である。（ い ）は情報理論における（ う ）であり、機械学習において損失関数としてよく用いられる。

$$p = (p_1, \dots, p_k)^T, \quad \sum_{j=1}^k p_j = 1, \quad 0 \leq p_j \leq 1 \quad (j = 1, \dots, k)$$



✓ 空欄（ あ ）に当てはまる選択肢を以下のうちから1つ選べ。 *

1/1

$$\sum_{i=1}^n \sum_{j=1}^k p_j^{x_{ij}}$$

☐ A

$$\prod_{i=1}^n \prod_{j=1}^k p_j^{x_{ij}}$$

☒ B

$$\sum_{i=1}^n \prod_{j=1}^k p_j^{x_{ij}}$$

☐ C

$$\prod_{i=1}^n \sum_{j=1}^k p_j^{x_{ij}}$$

☐ D

✓ 空欄（ い ）に当てはまる選択肢を以下のうちから1つ選べ。 *

1/1

$$-\sum_{i=1}^n \prod_{j=1}^k x_{ij} \log p_j$$

☐ A

$$-\sum_{i=1}^n \sum_{j=1}^k x_{ij} \log p_j$$

☒ B


$$-\sum_{i=1}^n \sum_{j=1}^k p_j \log x_{ij}$$

☐ C

$$-\sum_{i=1}^n \prod_{j=1}^k p_j \log x_{ij}$$

☐ D

✓ 空欄（ う ）に当てはまる語句を以下のうちから1つ選べ。 *

1/1

☐ ジニ不純度

☐ エントロピー

☐ 相互情報量

☒ 交差エントロピー


情報理論に関して、事象 x に対して確率 p があるとき、そのエントロピー（平均情報量）の式は（ あ ）である。さらに確率 q としたとき、交差エントロピーの式は（ い ）のように表すことができる。また、確率分布 P, Q があって、確率変数を $p(x), q(x)$ としたとき、 $r(x)$ が以下のような式を満たすとする、KLダイバージェンス $DKL(p||q)$ を表す式は（ う ）となり、JSダイバージェンス $DJS(p||q)$ を表す式は（ え ）となる。

$$r(x) = \frac{p(x) + q(x)}{2}$$



✓ 空欄（ あ ）に当てはまる式を以下のうちから選べ。 *

1/1

$$\sum_{i=1}^n p(x_i) \log p(x_i)$$

☐ A

$$-\sum_{i=1}^n p(x_i) \log p(x_i)$$

☒ B

$$\sum_{i=1}^n p(x_i) \log (1 - p(x_i))$$

☐ C

$$-\sum_{i=1}^n p(x_i) \log (1 - p(x_i))$$

☐ D

✓ 空欄（ い ）に当てはまる式を以下のうちから選べ。 *

1/1

$$-\log \frac{p(x)}{q(x)}$$

☐ A

$$-\log \frac{p(x)}{q(x)}$$

☐ B

$$-P(x)\log Q(x)$$

☒ C

$$P(x)\log Q(x)$$

☐ D

✓ 空欄（ う ）に当てはまる式を以下のうちから選べ。 *

1/1

$$\sum_x p(x) \log \frac{p(x)}{q(x)}$$

☒ A

$$\sum_x p(x) \log \frac{q(x)}{p(x)}$$

☐ B

$$\sum_x p(x) \log \frac{p(x)}{r(x)} + \sum_x q(x) \log \frac{q(x)}{r(x)}$$

☐ C

$$\sum_x p(x) \log \frac{q(x)}{r(x)} - \sum_x q(x) \log \frac{q(x)}{r(x)}$$

☐ D

✓ 空欄（ え ）に当てはまる式を以下のうちから選べ。 *

1/1

$$\sum_x p(x) \log \frac{p(x)}{q(x)}$$

☐ A

$$\sum_x p(x) \log \frac{q(x)}{p(x)}$$

☐ B


$$\sum_x p(x) \log \frac{p(x)}{r(x)} + \sum_x q(x) \log \frac{q(x)}{r(x)}$$

☒ C

$$\sum_x p(x) \log \frac{q(x)}{r(x)} - \sum_x q(x) \log \frac{q(x)}{r(x)}$$

☐ D

- ✓ k近傍法を用いて下図のデータ a を赤または青に分類したい。k=5のとき、k=9のときのそれぞれでデータ a は赤と青のどちらに分類されるか、正しい選択肢を1つ選べ。 *1/1



- ☒ k=5 : 青 k=9 : 赤
- ☐ k=5 : 赤 k=9 : 赤
- ☐ k=5 : 赤 k=9 : 青
- ☐ k=5 : 青 k=9 : 青



✓ パターン認識のアルゴリズムの説明文として、以下のうち誤っている選択肢を1つ選べ。 *1/1

- ☐ k近傍法において $k=1$ のとき、最近傍法（1-NN）と呼ばれることがある。
- ☐ k近傍法は、新たなデータが与えられたとき、そのデータから近い任意の数 k 個のデータの中で、最も属するデータが多いクラスに新たなデータを分類するアルゴリズムである。
- ☒ kd-treeは2次元のデータ群に用いるアルゴリズムであり、3次元以上のデータ群に用いることができない。 ✓
- ☐ 近似最近傍探索とは、近似解を求めることによって計算量を減らすことができる探索法である。

- ✓ コサイン距離の式とマハラノビス距離の式の組み合わせで正しい選択肢 *1/1 を1つ選べ。

コサイン距離：

$$\text{Cosine}(x, y) = \frac{\sqrt{\sum_i x_i^2} \sqrt{\sum_i y_i^2}}{\sum_i x_i y_i},$$

マハラノビス距離：

$$d = \sqrt{(\vec{x} - \vec{\mu}) \Sigma (\vec{x} - \vec{\mu})^T}$$

☐ A

コサイン距離：

$$\text{Cosine}(x, y) = \frac{\sum_i x_i y_i}{\sqrt{\sum_i x_i^2} \sqrt{\sum_i y_i^2}},$$

マハラノビス距離：

$$d = \sqrt{(\vec{x} - \vec{\mu}) \Sigma^{-1} (\vec{x} - \vec{\mu})^T}$$

☐ B

コサイン距離：

$$\text{Cosine}(x, y) = \frac{\sqrt{\sum_i x_i^2} \sqrt{\sum_i y_i^2}}{\sum_i x_i y_i},$$

マハラノビス距離：

$$d = \sqrt{(\vec{x} - \vec{\mu})^T \Sigma (\vec{x} - \vec{\mu})}$$

☐ C

コサイン距離：

$$\text{Cosine}(x, y) = \frac{\sum_i x_i y_i}{\sqrt{\sum_i x_i^2} \sqrt{\sum_i y_i^2}},$$

マハラノビス距離：

$$d = \sqrt{(\vec{x} - \vec{\mu})^T \Sigma^{-1} (\vec{x} - \vec{\mu})}$$

☒ D



- ✓ 距離の計算方法には種類があり、目的に応じて使い分けられている。それぞれの距離の性質や利用事例について、以下のうち正しい選択肢を1つ選べ。 *1/1

- ☐ マンハッタン距離は、異常検知の分野で用いられる最も代表的な距離である。
- ☐ マンハッタン距離は、2点間の直線距離を求めたいときに用いられる。
- ☒ コサイン距離は、単語や文章をベクトル化して類似度を測る場合に用いられる。 ✓
- ☐ Lp距離は、データ間の相関を考慮した距離である。



✕ 教師あり学習、教師なし学習について、以下のうち正しい選択肢を1つ *0/1
選べ。

- ☒ 教師なし学習におけるクラスタリングとは、高次元データを低次元データ空間にマッピングするタスクであり、代表的なアルゴリズムには、主成分分析、t-SNE などがある。 ✕
- ☐ 教師なし学習における異常検出とは、データの類似性に基づいた潜在的な構造やカテゴリーを検出するタスクであり、代表的なアルゴリズムには、k-平均法、階層的クラスタリングなどがある。
- ☐ 教師あり学習における分類タスクは離散値を予測するタスクであり、代表的なアルゴリズムには、決定木、サポートベクターマシンなどがある。
- ☐ 教師あり学習における回帰タスクは連続値を予測するタスクであり、代表的なアルゴリズムには、線形回帰、ロジスティック回帰などがある。

✓ 教師あり学習アルゴリズムとして、木構造を利用した決定木と呼ばれるものがある。 *1/1
このアルゴリズムの特徴として、不適切な選択肢を1つ選べ。

- ☐ 訓練データに過適合しないように、ノードに割り当てられたデータが少なくなりすぎないように制限する。
- ☐ 不純度を表す指標として、エントロピーやジニ不純度を用いる。
- ☐ データを分割する際には、分割後のノードが持つデータの不純度が小さくなるように分割する。
- ☒ 分類タスクのみに適用できるアルゴリズムである。 ✓

✓ 半教師あり学習について、以下のうち正しい選択肢を 1 つ選べ。 *

1/1

- ☐ 大量の教師ありデータと、少量の教師なしデータを使って学習する方法である。
- ☒ 半教師あり分類学習では、教師ありデータから分類器を作り、それを使って教師なしデータにラベルを付ける。 ✓
- ☐ 半教師あり学習における多様体の仮定では、近いポイントにあるデータ同士は、ラベルを共有する可能性が高くなると想定できる。
- ☐ 半教師ありクラスタリングには、「ラベルプロパゲーション」や「Self-Training」と呼ばれる手法などがある。

✓ 半教師あり学習の主な手法について、以下のうち最も不適切な選択肢を *1/1
1 つ選べ。

- ☐ 自己学習（Self-Training）は、ラベル付きデータセットを使用して学習を行い、ラベルなしデータセットを分類するための手法である。
- ☒ 半教師ありクラスタリングは、クラスタリングの問題を解くために大量のラベル付きデータと少量のラベルなしデータを使用して、新しいクラスセグメントを見つけ出すための手法である。 ✓
- ☐ 共訓練（Co-Training）は、データセットを複数の異なるビュー（データの異なる側面や特徴）に分割し、それぞれのビューを利用して、ラベル付きデータセットを基に複数の教師付き分類器を生成する手法である。
- ☐ グラフベースの手法では、ラベル付きデータとラベルなしデータを組み合わせて、データ間の関係をグラフとして表現し、このグラフ上でラベル情報を伝播させる。



✓ バイアスとバリエーションのトレードオフについて、単純なモデルほどバイアスが（ あ ）傾向にあり、複雑なモデルほどバリエーションが（ い ）傾向がある。 *1/1

（ あ ）（ い ）の組み合わせとして、以下のうち正しい選択肢を1つ選べ。

- ☒ （あ）高い （い）高い ✓
- ☐ （あ）低い （い）低い
- ☐ （あ）低い （い）高い
- ☐ （あ）高い （い）低い

ベルマンは、未知の複雑な関数を学習によって得るために必要となるデータ数が、次元の増加に対して、（ あ ）的に増加することを指摘した。これは次元の呪いと呼ばれ、そのひとつとして、高次元空間ではデータのほとんどが超球面上に分布してしまう球面集中現象が起こる。次元の呪いを回避するために、使用する特徴量を最適化する（ い ）やデータを低次元空間へ変換する次元削減などが有効である。

✓ （ あ ）（ い ）の組み合わせとして、以下のうち正しい選択肢を1つ選べ。 *1/1

- ☐ （あ）指数関数 （い）ベイズ最適化
- ☒ （あ）指数関数 （い）特徴量選択 ✓
- ☐ （あ）1次関数 （い）ベイズ最適化
- ☐ （あ）1次関数 （い）特徴量選択

教師なし学習アルゴリズムは、次元削減するアルゴリズムとして（ あ ）なデータに対してうまく機能する主成分分析が有名である。しかし、主成分分析は高次元空間上で遠くに位置するデータは、次元削減後の低次元空間上で（ い ）に焦点を当てており、類似するデータの局所的な構造を保つのは難しい。上記の課題を解決するために、（ う ）といったアルゴリズムが考案されている。

✕ 空欄（ あ ）（ い ）に当てはまる語句の組み合わせを以下のうちか *0/1
ら1つ選べ。

- ☒ （あ）線形 （い）近くに位置させること
- ☐ （あ）非線形 （い）遠くに位置させること
- ☐ （あ）非線形 （い）近くに位置させること
- ☐ （あ）線形 （い）遠くに位置させること

✕

✓ 空欄（ う ）に当てはまる語句を以下のうちから1つ選べ。 *

1/1

- ☒ SNE
- ☐ GBDT
- ☐ LightGBM
- ☐ CART

✓

機械学習の誤差は、バイアス・バリエンス・ノイズの3成分に分類することができる。Dをデータ集合、xを説明変数、h(x)を理想的な予測モデル、y(x)を予測モデル、tを目的変数の真値としたとき、以下のような式になった。

$$E(L) = \int \{y(x) - h(x)\}^2 p(x) dx + \iint \{h(x) - t\}^2 p(x, t) dx dt$$



以上の式をバイアス、バリエーション、ノイズにあたる部分に分解したいと考えると次のようになる。

バイアスの二乗の式 . . . (あ)

バリエーション . . . (い)

ノイズ . . . (う)

✓ 空欄 (あ) に当てはまる式を以下のうちから選べ。 *

1/1

$$\int \{E_D[y(x; D)] - h(x)\}^2 p(x) dx$$

☒ A



$$\int E_D[\{y(x; D) - E_D[y(x; D)]\}^2] p(x) dx$$

☐ B

$$\int \{y(x; D) - h(x)\}^2 p(x) dx$$

☐ C

$$\iint \{h(x) - t\}^2 p(x, t) dx dt$$

☐ D



✓ 空欄（ い ）に当てはまる式を以下のうちから選べ。 *

1/1

$$\int \{E_D[y(x; D)] - h(x)\}^2 p(x) dx$$

☐ A

$$\int E_D[\{y(x; D) - E_D[y(x; D)]\}^2] p(x) dx$$

☒ B



$$\int \{y(x; D) - h(x)\}^2 p(x) dx$$

☐ C

$$\iint \{h(x) - t\}^2 p(x, t) dx dt$$

☐ D



✓ 空欄（ う ）に当てはまる式を以下のうちから選べ。 *

1/1

$$\int \{E_D[y(x; D)] - h(x)\}^2 p(x) dx$$

☐ A

$$\int E_D[\{y(x; D) - E_D[y(x; D)]\}^2] p(x) dx$$

☐ B

$$\int \{y(x; D) - h(x)\}^2 p(x) dx$$

☐ C

$$\iint \{h(x) - t\}^2 p(x, t) dx dt$$

☒ D





モデルを学習して検証用データで精度を確認することは、モデルの汎化性能を向上するためにとても重要な項目である。



✓ 以下のうちから、検証用データの目的として正しい説明文を1つ選べ。 * 1/1

- ☐ 未知のデータに対してどれだけの精度があるか最終的に確認するため。
- ☐ データにどれだけのノイズが紛れているかなどを確認するため。
- ☒ モデルのハイパーパラメータを調整するため。 ✓
- ☐ より複雑なデータを検証用とすることで、訓練用データから1段階レベルを上げた学習を行うため。

今回は、バイアスとバリエーションのトレードオフについて確認するため、データをいくつか用意した。次元数をハイパーパラメータとして適切な関数の次元数を探りたいと思う。以下の結果を見ると次元数が1のときは（あ）であり、次元数が20のときは（い）を起こしていると思われる。このように次元数を変えて実行を行っていき適切なハイパーパラメータの値を求めていくことができる。



✓ 空欄（あ）、（い）に当てはまる語句の組み合わせとして正しいものを以下のうちから1つ選べ。 *1/1


- ☒ （あ）過少適合 （い）過剰適合 ✓
- ☐ （あ）過剰適合 （い）過少適合
- ☐ （あ）過剰適合 （い）過剰適合
- ☐ （あ）過少適合 （い）過少適合

バイアス・バリエーションのトレードオフに関して、
モデルがバイアス高・バリエーション低の状態では主に（ う ）が問題となり、
モデルがバイアス低・バリエーション高の状態では主に（ え ）が問題となる。

✓ 空欄（ う ）,（ え ）の組み合わせとして最も適切なものを以下から1つ選べ。 *1/1

- ☐ （う）勾配爆発 （え）勾配消失
- ☒ （う）未学習 （え）過学習 ✓
- ☐ （う）過学習 （え）未学習
- ☐ （う）勾配消失 （え）勾配爆発

そこで、上記のグラフに次元数が10の時を加えて、バイアスとバリエーションを可視化したグラフを作成した。下記のグラフを見ると青色のグラフが（ お ）で、オレンジ色のグラフが（ か ）である。



✓ 空欄（ お ）、（ か ）に当てはまる語句の組み合わせとして正しい *1/1
ものを以下のうちから1つ選べ。

- ☐ （お）バリエーション （か）バリエーション
- ☐ （お）バリエーション （か）バイアス
- ☒ （お）バイアス （か）バリエーション ✓
- ☐ （お）バイアス （か）バイアス

機械学習分野において、学習データに対して、値が0~1の範囲に収まるように加工を施すことを正規化という。

正規化により最小値を 0、最大値を 1 にすることでスケールの違いからくる影響を緩和することができる。具体的には（ あ ）効果がある。

✓ （ あ ）に入る文として最も不適切な選択肢を1つ選べ。 * 1/1

- ☐ ある特徴量が過度に重視されることを防ぐ
- ☒ 過少適合を抑制する ✓
- ☐ 特徴量のスケールの違いによって学習の収束が遅くなることを防ぐ
- ☐ 勾配消失や勾配爆発を起きにくくする

機械学習において、モデルがどの程度良いものなのかを考える際、既存のデータを最大限活用して検証を行っていきたい。その際に検証手法の主たるものとして、ホールドアウト法とk-分割交差検証法が挙げられる。



✓ 検証手法であるホールドアウト法とk-分割交差検証法について述べた以下の4つのうち、各手法の正しい説明文を1つ選べ。 *1/1

- ☐ どのようなデータセットでも、交差検証の中でさらに交差検証を行うことは理論上計算時間が膨大になりすぎるので推奨されない
- ☐ k-分割交差検証法は、ホールドアウト法より一般的に精度が高いがどのような工夫を行っても、必ず2倍以上の時間を要してしまう
- ☒ ホールドアウト法・k-分割交差検証法のどちらでも検証集合またはテスト集合に対する予測結果を用いて、モデルの汎化性能を評価することは共通している ✓
- ☐ k-分割交差検証法は、又の名をk-meansと言い、学習と検証を行って検証値の中央値を出す

✓ 機械学習で扱うデータとして、訓練データ、検証データ、テストデータが挙げられる。各データを説明する文章として正しい説明文を1つ選べ。 *1/1

- ☐ 検証集合はハイパーパラメータの調整を行うための集合なので、調整しない場合は必要がない
- ☐ データ集合内のデータ数が少なかったため、重複を許すように訓練集合と検証集合を作成したが、テスト集合には重複を許さないように作成することで汎化性能の信頼度は下がらないようになる。
- ☒ データ集合を7:3に分割し、7割を訓練と検証用にし、3割をテスト用に用いて汎化性能を評価した ✓
- ☐ 用意する各データ数の比率は、モデルによって定められているので、必ず確認を行う。

機械学習において、モデルがどの程度良いものなのかを考える際、既存のデータを最大限活用して検証を行っていきたい。その際に検証手法の主たるものの一つとして、交差検証（クロスバリデーション）が挙げられる。



✓ 以下のうちから、誤っている説明文を1つ選べ。 *

1/1

- ☐ サンプルサイズが小さいときは、計算コストは高いが精度が高くなるリーブワンアウト法が有効。
- ☐ 汎化性能を評価する手法で、回帰・分類いずれにも用いることができる。
- ☐ 50個のデータに対して、5分割の交差検証法を行うとすると、各検証データは10個になる。
- ☒ 交差検証法はホールドアウト法と比べると、評価結果の信頼性は低くなる。 ✓

Pythonのsklearnというライブラリを用いて、アヤメデータにk-分割交差検証法を実行しようと考えた。以下はそのコードと結果の一部である。

```
# sklearnでk-分割交差検証法をした時に各グループに含まれるラベル数
kf = KFold(5, shuffle=True)
i = 0
for train_index, test_index in kf.split(X):
    i += 1
    print(f"¥n{i}グループ目の訓練用データに含まれる各ラベル")
    train_y = y[train_index]
    for c in range(3):
        print(f"iris.target_names[c]: {list(train_y).count(c)}個")
    print(f"{i}グループ目のテスト用データに含まれる各ラベル数")
    test_y = y[test_index]
    for c in range(3):
        print(f"iris.target_names[c]: {list(test_y).count(c)}個")
```

setosa: 50個
versicolor: 10個
virginica: 5個

1グループ目の訓練用データに含まれる各ラベル

setosa: 39個
versicolor: 8個
virginica: 5個

1グループ目のテスト用データに含まれる各ラベル数

setosa: 11個
versicolor: 2個
virginica: 0個

以上の結果からk-分割交差検証法についてまとめた。k-分割交差検証法では、データを（ あ ）個に分割し、（ い ）個の学習用データと（ う ）個のテスト用データで学習と検証を（ え ）通り繰り返し、検証値の（ お ）を求める。また、k-分割交差検証法は、各セットを並列で実行することが（ か ）である。しかし、上の結果を見ると、（ き ）ということが分かる。

✓ 空欄（ あ ）、（ い ）、（ う ）に当てはまる語句の組み合わせとして正しいものを以下のうちから1つ選べ。 *1/1

- ☐ （あ）k-1 （い）k （う）k
- ☐ （あ）k-1 （い）k-1 （う）1
- ☒ （あ）k （い）k-1 （う）1
- ☐ （あ）k （い）1 （う）k-1



✓ 空欄（ え ）、（ か ）に当てはまる語句の組み合わせとして正しいものを以下のうちから1つ選べ。 *1/1

- ☐ （え）k-1 （か）不可能
- ☐ （え）k （か）不可能
- ☐ （え）k-1 （か）可能
- ☒ （え）k （か）可能



✓ 空欄（ き ）に当てはまる語句を以下のうちから1つ選べ。 * 1/1

- ☒ テスト用データ内にvirginicaのデータがないグループがあるので、各セットのクラスの比率が同じになるように分割方法を工夫した層化k分割交差検証法を用いるべきである。 ✓
- ☐ k-分割交差検証法はグループを分けるほど精度が上がるので、さらに細かく分けた場合での検証も行うべきである。
- ☐ k-分割交差検証法はデータが均一に揃った上でデータを最大限に活用できる手法なので、versicolorとvirginicaのデータ数をsetosaと同数の50個にしなければならない。
- ☐ k-分割交差検証法は全てのデータが使われないので、グループごとにどのデータが使われていないのかをprintするコードを記入するべきである。



- ✓ データセットの分け方にはいくつか方法があり、最も単純な方法に（^{*1/1}あ）がある。（あ）では、データセットを訓練データと評価データに固定的に分割をする。ここで、時系列に依存しないデータセットは（い）ことが望ましい。しかし、時系列データの場合は（う）必要がある。

（あ）（い）（う）に当てはまる文章の組み合わせとして適切な選択肢を1つ選べ。

- ☐ （あ）交差検証法 （い）データを収集した順を保ったまま分割される （う）ランダムに分割される
- ☐ （あ）hold-out法 （い）データを収集した順を保ったまま分割される （う）ランダムに分割される
- ☒ （あ）hold-out法 （い）ランダムに分割される （う）データを収集した順を保ったまま分割される ✓
- ☐ （あ）交差検証法 （い）ランダムに分割される （う）データを収集した順を保ったまま分割される

- ✓ データセットを K のブロック(fold)に分割し、K-1 ブロックを訓練に、^{*1/1}残りの1ブロックを評価用データに使用する方法をK分割交差検証（K-fold cross validation）とよぶ。評価用データの選び方には K 通りあるが、このすべての場合についてモデルの訓練および評価をし、それらの性能の平均値をとって最終的なモデルの性能とする。なお、分類タスクの場合では、ブロックごとに含まれるクラスの割合を等しくすることがしばしば行われる。これを（あ）という。

（あ）に当てはまる選択肢を1つ選べ。

- ☐ Bootstrap（ブートストラップ）
- ☐ leave-one-out
- ☒ Stratified k-fold CV ✓
- ☐ Group k-fold CV

✕ 交差検証において、一般的にはブロック数を増やすほど訓練データの量を確保できるため、データセット全体で学習させた場合に近い精度評価ができる。反面、ブロック数に比例してモデルの訓練にかかる計算時間が増える。 *0/1

例えば、ブロック数を2から4に増やした場合、学習にかかる計算量は（ え ） 倍にふえ、訓練データに使用するデータは（ お ） 倍に増える。よって、ブロック数を無闇に増やしてもデータセットの数には限りがあるため、計算時間やデータセットの量を考慮してブロック数を設定すると良い。

（ え ）（ お ）に当てはまる文章の組み合わせとして適切な選択肢を1つ選べ。

- ☐ （え） 2 （お） 1.5
- ☒ （え） 3 （お） 3
- ☐ （え） 3 （お） 2
- ☐ （え） 2 （お） 1.75

✕

✓ 検証手法であるホールドアウト法とk-分割交差検証法について、以下のうち正しい選択肢を1つ選べ。 *1/1

- ☒ ホールドアウト法・k-分割交差検証法のどちらでも、検証集合またはテスト集合に対する予測結果を用いて、モデルの汎化性能を評価することは共通している。 ✓
- ☐ k-分割交差検証法は、又の名をk-meansと言い、学習と検証を行って検証値の中央値を出す。
- ☐ どのようなデータセットでも、交差検証の中でさらに交差検証を行うことは理論上計算時間が膨大になりすぎるので、推奨されない。
- ☐ k-分割交差検証法は、ホールドアウト法より一般的に精度が低く、処理により多くの時間を要してしまう。

- ✓ 分類タスクにおける性能指標について、以下のうち正しい選択肢を1つ *1/1 選べ。

$$\frac{2TP}{2TP+FP+FN}$$

- ☐ 正解率 (accuracy) は、以下のよう
に表される。

$$\frac{TP}{TP+FP}$$

- ☐ 再現率・偽陰性率 (recall) は、
以下のように表される。

$$\frac{FP}{FP+TN}$$

- ☒ 偽陽性率 (False positive rate) ✓
は、以下のように表される。

$$\frac{TP}{TP+FN}$$

- ☐ 適合率・真陽性率 (precision)
は、以下のように表される。

✓ 各タスクで用いられる代表的な性能指標の特徴について、以下のうち誤っている選択肢を1つ選べ。 *1/1

- ☐ PR曲線では、Recall（再現率）と Precision（適合率）を用いた評価を行う。
- ☒ AUC の値は0から1までの範囲を持ち、この値が0.5を下回る場合、モデルの推定はランダムな推定よりも優れていることを示す。 ✓
- ☐ Macro平均は、各クラスが同等に重要であると考えられる場合や、データの少ないクラスも重視したい場合に適している。
- ☐ 決定係数は、 $1 - \text{SSE}/\text{SST}$ で計算される。

✗ 機械学習で用いられる代表的な性能指標の特徴について、以下のうち誤っている選択肢を1つ選べ。 *0/1

- ☒ PR曲線は分類モデルの性能を評価するための指標であり、クラスの不均衡が存在する場合に有効である。 ✗
- ☐ IoU はバウンディングボックスが重なっている部分を両者が合わさってカバーする領域で割ることで、予測された物体の位置と実際の位置の一致度を正確に評価することができる。
- ☐ ROC曲線は偽陽性率と真陽性率を基にグラフを作成しROC曲線の下領域であるAUCを計算することで、分類器の全体的な性能を評価する。
- ☐ AP は各物体クラスに対する予測の精度をPR曲線の下領域の面積を計算し、それらの平均値を取ることで評価する指標である。

データの個数を N 、真の値を y_i 、予測値を $\hat{y}_i$ とする。



- ✓ (あ) (い) (う) に対応する性能指標の計算式について、以下のうち正しい選択肢を1つ選べ。 *1/1

$$\begin{aligned} \text{(あ)} \quad \text{MAE} &= \frac{1}{N} \sum_{i=1}^N |y_i - \hat{y}_i| \\ \text{(い)} \quad \text{MSE} &= \frac{1}{N} \sum_{i=1}^N (y_i - \hat{y}_i)^2 \\ \text{(う)} \quad \text{RMSE} &= \sqrt{\frac{1}{N} \sum_{i=1}^N (y_i - \hat{y}_i)^2} \end{aligned}$$

☒ C


$$\begin{aligned} \text{(あ)} \quad \text{MAE} &= \frac{1}{N} \sum_{i=1}^N |y_i - \hat{y}_i| \\ \text{(い)} \quad \text{MSE} &= \frac{1}{N} \sum_{i=1}^N (y_i - \hat{y}_i)^2 \\ \text{(う)} \quad \text{RMSE} &= \frac{1}{N} \sum_{i=1}^N \sqrt{(y_i - \hat{y}_i)^2} \end{aligned}$$

☐ A

$$\begin{aligned} \text{(あ)} \quad \text{MAE} &= \frac{1}{N} \sum_{i=1}^N (y_i - \hat{y}_i)^2 \\ \text{(い)} \quad \text{MSE} &= \frac{1}{N} \sum_{i=1}^N |y_i - \hat{y}_i| \\ \text{(う)} \quad \text{RMSE} &= \sqrt{\frac{1}{N} \sum_{i=1}^N (y_i - \hat{y}_i)^2} \end{aligned}$$

☐ D

$$\begin{aligned} \text{(あ)} \quad \text{MAE} &= \frac{1}{N} \sum_{i=1}^N (y_i - \hat{y}_i)^2 \\ \text{(い)} \quad \text{MSE} &= \frac{1}{N} \sum_{i=1}^N |y_i - \hat{y}_i| \\ \text{(う)} \quad \text{RMSE} &= \frac{1}{N} \sum_{i=1}^N \sqrt{(y_i - \hat{y}_i)^2} \end{aligned}$$

☐ B

学習を終えたモデルが必ずしも良い性能とは限らない。しかし、全ての予測に対して正解かどうか網羅的に判断することは難しい。そのため、学習したモデルの良し悪しを測るためには定量的な尺度を設定する必要がある。機械学習においてそのような尺度を評価指標という。



✕ 以下のうちから、評価指標に関して誤っている説明文を1つ選べ。 *

0/1

- ☐ 平均二乗誤差(MSE)は、各データについて予測値と真値の差の二乗を計算した後、その平均を取る手法で、外れ値の影響を受けやすい。
- ☐ RMSEとMAEの違いは根号($\sqrt{\quad}$)の有無だけである。
- ☒ RMSEは大きな間違いをより重要視していて、回帰モデルの最も一般的な性能評価指標である。 ✕
- ☐ 決定係数は説明変数が多いほど値が1に近づくので、一概に性能を確かめられないときがある。

また、性能指標の一つとして予想結果と真の結果を行列の形にした混同行列が考えられる。今回、ある病原体の検査薬を用いて、感染者と思われる1000名に対して検査を行った。その結果、予想したデータと真の結果を比べた際に以下の混同行列を作成して性能を評価した。

		真の結果	
		陽性	陰性
予測結果	陽性	950	15
	陰性	25	10

✕ 以下のうちから、正しい説明文を1つ選べ。 *

0/1

- ☐ 正答率が97%である。
- ☒ 偽陰性の割合が50%以上なので、性能が低いといえる。 ✕
- ☐ 再現率よりも適合率の方が高い。
- ☐ 偽陽性率は70%を超えている。



識別タスクにおいて2値分類などの評価を行う際、予測ラベルと真のラベルの間で下のような表を考えることができる。これを（ あ ）という。真の値が陽性（正例）のものうち、陽性（正例）と判断できたものの割合を評価する再現率を用いることがある。

		真の結果	
		陽性	陰性
予測結果	陽性	TP	FP
	陰性	FN	TN

✓ 空欄（ あ ）に当てはまる語句を以下のうちから1つ選べ。 *

1/1

- ☐ ガウス行列
- ☒ 混同行列
- ☐ アダマール行列
- ☐ 分散共分散行列



✓ 「再現率 (recall)」に当てはまる式を以下のうちから1つ選べ。*

1/1

$$\frac{TP+TN}{TP+TN+FN+FP}$$

☐ A

$$\frac{TP}{TP+FP}$$

☐ B

$$\frac{TP}{TP+FN}$$

☒ C

$$\frac{FP}{FN+FP}$$

☐ D

モデルの検証用データに対する正解率やテスト用データに対しての汎化性能など、モデルがどの程度の精度なのかを数値的に確認する必要がある。正解率を用いて評価を行う際、得られた正解率がモデルの評価として適さず、ROC曲線を用いて評価を行う場合がある。



✓ 正解率を用いたモデルの評価が適さない場合について、以下のうちから *1/1
正しい選択肢を 1 つ選べ。

- ☐ 分類問題を評価しているとき。
- ☐ 教師ラベル数が10未満のとき。
- ☐ 教師ラベル数が10以上のとき。
- ☒ 評価データセットの内で各ラベルのデータ数が不均衡なとき。 ✓

FPRを横軸に、TPRを縦軸にプロットした図をROC曲線と呼ぶ。ROC曲線を利用すると、視覚的に良いモデルを選択することができる。このとき、FPRとTPRは以下のように定義する。

$$\text{True Positive Rate (TPR)} : \frac{TP}{TP + FN}$$

$$\text{False Positive Rate (FPR)} : \frac{FP}{TN + FP}$$

✓ ここでの良いモデルとは、どのような条件を満たすモデルか。以下のうちから、正しい選択肢を 1 つ選べ。 *1/1

- ☐ FPRが高く、TPRが低い
- ☐ FPRが低く、TPRも低い
- ☒ FPRが低く、TPRが高い ✓
- ☐ FPRが高く、TPRも高い



✓ ROC曲線はモデルの良し悪しを直観的に把握しやすいが、さらにROC曲線に基づいて計算される客観的な数値指標もある。この指標は、AUCと呼ばれる。以下のうちから、正しい説明文を1つ選べ。 *1/1

- ☒ 完全にランダムな予測をするモデルに対し、AUCを計算すると、0.5になる。 ✓
- ☐ AUCは赤池情報量基準といい、説明変数が多いほど表現力が高まるのを抑えるため、説明変数の数に応じてペナルティが与えられる。
- ☐ 2つのモデルのROC曲線をプロットしたとき、どちらのモデルのAUCが大きいかを判断することはできないので、.auc()というメソッドを使用することで求められる。
- ☐ AUCはROC曲線の微分値の和で求めることができ、最大値は1である。

機械学習モデルを作成する主な目的は、未知のデータに対して高い精度で予測することである。自然言語モデルの予測性能の良さを評価する指標として、よく使われるものにパープレキシティ（perplexity）がある。

✓ パープレキシティ（perplexity）は言語モデルが次に来る単語を予測する際の（あ）を表す指標であり、値が小さいほどモデルの予測性能が（い）と判断される。（あ）（い）に当てはまる文章の組み合わせとして、適切な選択肢を1つ選べ。 *1/1

- ☐ （あ）再現率 （い）高い
- ☐ （あ）不確実性 （い）低い
- ☒ （あ）不確実性 （い）高い ✓
- ☐ （あ）再現率 （い）低い

- ✓ ある言語モデルの改良前後で、パープレキシティの値が100から25に変化した。この変化が意味する内容として、適切な選択肢を1つ選べ。 *1/1
- ☒ モデルが次の単語を予測する際の実効的な選択肢の数が100個相当から25個相当に減り、予測の不確実性が低下した ✓
 - ☐ パープレキシティの値が小さくなると過学習の傾向を示すため、汎化性能が悪化した可能性がある
 - ☐ パープレキシティが4分の1に減少したため、モデルの予測精度も4分の1に低下した
 - ☐ 次に来る単語の予測における正解率が1/100から1/25に向上したため、予測性能が4倍に改善した

このフォームは デロイト トーマツ ディープスクエア株式会社 内部で作成されました。
このフォームが不審だと思われる場合 [報告](#)

Google フォーム



