

修了試験B-1

合計点 48/52 点 ?

合格点 85%以上 (44以上/52)

0 / 0 ポイント

受験者情報の登録

登録メールアドレス *

htanaka@777.so-net.jp

御名前 *

田中 秀伯

修了試験問題

48 / 52 ポイント

- ✓ VGGなどの画像認識モデルでは、層を深くすることで勾配が消失し学習 *1/1
が不安定になることが問題として挙げられている。そこで、ResNet-50
ではより効率的に学習を行うために（ あ ）が実装されている。（
あ ）は畳み込み層を3つ並べたもので、（ い ）ことが特徴である。

（ あ ）（ い ）に当てはまる組み合わせについて、以下のうち最も
適切なものを1つ選べ。

- ☒ （あ）ボトルネックブロック （い）1×1の畳み込み層を配置しチャンネル数を操作する ✓
- ☐ （あ）ビルディングブロック （い）カーネルが小さい畳み込み層を配置する
- ☐ （あ）ビルディングブロック （い）1×1の畳み込み層を配置しチャンネル数を操作する
- ☐ （あ）ボトルネックブロック （い）カーネルが小さい畳み込み層を配置する



- ✓ 学習層が深くなることでより性能を向上させることができるが、一方で学習がうまく進まないという問題もある。そのため、CNNには層を深くするために多くの工夫がなされてきた歴史がある。(あ)は、VGG系ネットワークの設計を参考にしつつ、Identity Mappingと呼ばれるショートカット接続を導入することで、深いネットワークの学習を可能にした。 *1/1

(い)は(あ)を改良したモデルである。(い)は畳み込み層の幅を広げることで精度を向上させると同時に、モデルの深さを抑えることで学習時間の短縮と過学習のリスク低減を実現する点に特徴がある。

(あ)(い)に当てはまる組み合わせについて、以下のうち最も適切なものを1つ選べ。

- ☒ (あ) ResNet (い) WideResNet ✓
- ☐ (あ) GoogleNet (い) DenseNet
- ☐ (あ) DenseNet (い) WideDenseNet
- ☐ (あ) DenseNet (い) ResNet


- ✓ ResNetでは、既存手法における勾配消失問題を解決できるため有力とされていたが、層を非常に深くすることで性能を向上できる一方、深さの増加に伴って特徴の再利用が減少し、学習時間や計算量が増大することが課題となっていた。そこで、ResNetの拡張版としてWideResNetが提案された。WideResNetの説明文として、以下のうちから適切なものを1つ選べ。 *1/1

- ☐ WideResNetは、各残差ブロックに用いられている畳み込み層の数を少なくすることで、有効なブロックのみで構成されたモデルである。
- ☒ WideResNetは、各残差ブロックにおけるチャンネル数を増やすことによって、より効率的な学習を目指したモデルである。 ✓
- ☐ WideResNetは、各ブロックでの出力をその先のブロックの入力に組み込むことで、より表現力を高めたモデルである。
- ☐ WideResNetは、ドロップアウト層を残差ブロック内に配置することで、より汎化的な学習を目指したモデルである。

層を深く重ねたニューラルネットワークは、一般的に学習することが困難である。この問題を解決するモデルとして提案されたのが、ResNet である。ResNet の改良モデルとしてWide ResNet も提案されており、画像分類におけるベースモデルとしてしばしば用いられる。

WideResNet は、ResNetが残差接続によって層を深くしたのに対し、WideResNetは残差ブロック内の畳み込み層の出力チャンネル数を増やし、層を浅くしたモデルである。

- ✓ 以下の図は、ある残差ブロックを表したものである。以下の選択肢から、図の説明として誤っているものを1つ選べ。 ★1/1



- ☒ 残差ブロックの出力は、畳み込み層側の出力と残差ブロックへの入力との差である。 ✓
- ☐ 畳み込み層側の出力と残差ブロックへの入力値は同じサイズである。
- ☐ 残差ブロックに含まれる畳み込み層は2層である。
- ☐ 残差ブロックに含まれる畳み込み層のカーネルサイズは全て3×3である。

✓ Wide ResNet に関する説明として最も適切でない選択肢を以下から選べ。 *1/1

- ☐ 同程度のパラメータ数なら、WideResNetのほうがオリジナルのResNetよりも性能がよいことが確認された。
- ☐ ドロップアウトの有効性が確認された。
- ☐ WideResNetの実験から、ネットワークの幅を増加させることで、深さをそれほど増やさなくても高い性能を発揮することが確認された。
- ☒ 畳み込み層のフィルタを（3×3）以上に大きくすることで精度が向上することが確認された。 ✓



- ✓ コード1のプログラム内（ あ ）がある理由として、以下のうち正しい選択肢を1つ選べ。 *1/1

```
class ResBlock(nn.Module):

    def __init__(self, in_channels, out_channels, stride=1):
        super().__init__()
        self.expansion = 1 # 出力のチャンネル数を入力のチャンネル数の何倍に拡大するか

        # 1つ目の畳み込み層: 3x3の畳み込み
        self.conv1 = nn.Conv2d(in_channels, out_channels, kernel_size=3,
stride=stride, padding=1, bias=False)
        self.bn1 = nn.BatchNorm2d(out_channels)
        self.relu = nn.ReLU(inplace=True)

        # 2つ目の畳み込み層: 3x3の畳み込み
        self.conv2 = nn.Conv2d(out_channels, out_channels, kernel_size=3,
padding=1, bias=False)
        self.bn2 = nn.BatchNorm2d(out_channels)


        # スキップ接続のための層
        self.shortcut = nn.Sequential()
        if stride != 1 or in_channels != self.expansion * out_channels: ... (あ)
            self.shortcut = nn.Sequential(
                # 1x1の畳み込みで次元数を調整
                nn.Conv2d(in_channels, self.expansion * out_channels, kernel_size=1,
stride=stride, bias=False),
                nn.BatchNorm2d(self.expansion * out_channels)
            )

    def forward(self, x):
        out = self.relu(self.bn1(self.conv1(x)))
        out = self.bn2(self.conv2(out))
        out += self.shortcut(x)
        out = self.relu(out)
        return out
```

- ☐ ネットワークの非線形性を高めるため。
- ☐ 畳み込み層の重みを初期化するため。
- ☐ ネットワークの計算負荷を軽減するため。
- ☒ 主要な畳み込みパスの出力と残差接続の次元を一致させるため。



- ✓ Vision Transformerの事前学習に関する数値実験の結果として以下の図が *1/1 提示されている。左図は、事前学習データセットの違いによるImageNet Top-1 Accuracyを示している。右図は、JFTで使用する事前学習サンプル数とLinear 5-shot ImageNet Top-1 Accuracyの関係を示している。以下のうち、図の説明として最も不適切な選択肢を1つ選べ。



- ☐ JFT-300Mデータセットでの事前学習は、サブセットのサイズが大きくなるにつれて、5-shot ImageNet Top-1精度が向上することを示しており、大規模なデータセットでの事前学習が重要であることを強調している。
- ☐ データセットのサイズが大きいほど事前学習後の精度が向上することが観測されており、特にJFT-300Mの完全なデータセットを用いた事前学習は、他のサブセットサイズと比較しても最も高い精度を示している。
- ☐ ImageNetデータセットでの事前学習は、ImageNet-21kやJFT-300Mに比べてTop-1精度が低いですが、データセットのサイズが増えるほど精度が向上することを示している。
- ☒ ImageNet-21kデータセットでの事前学習は、JFT-300Mよりも高いTop-1精度を Vision Transformerにもたらすが、データサイズが小さくても十分な精度が得られることを示している。

✓ Vision Transformer (ViT) は、画像分類タスクで使用されるトランスフォーマーベースのモデルである。ViTは特定の構成とプロセスを持ち、これによって高い精度で画像を分類することが可能である。ViTのアーキテクチャに関する説明文について、以下のうちから誤っているものを1つ選べ。 *1/1

- ☒ CLSトークンは、画像の各パッチに個別に追加され、それぞれのパッチを独立して分類する。このプロセスにより、ViTは画像全体のクラス分類を行うことができる。 ✓
- ☐ トランスフォーマーの自己注意機構は、ViTにおいて重要な役割を果たす。これにより、異なるパッチ間の関連性を学習し、より有意義な特徴表現を生成する。
- ☐ ViTは、画像を小さなパッチに分割し、それぞれをベクトル化してシーケンスに変換する。これらのパッチに加えて、CLSトークンもシーケンスの最初に追加され、このCLSトークンを使用して画像全体の分類を行う。
- ☐ ViTのアーキテクチャでは、トランスフォーマーのエンコーダを使用している。これは各パッチから得られる特徴を相互に関連付けることで、画像全体の理解を深めている。

✓ Vision Transformer (ViT) は、画像分類タスクで使用されるトランスフォーマーベースのモデルである。VisionTransformerのモデルへの画像特徴量の入力方法について、以下のうちから誤っている物を1つ選べ。 *1/1

- ☐ ViT は入力画像をパッチに分割し、それぞれのパッチを独立したベクトルとして処理します。その後、CLSトークンを追加し、各パッチとCLSトークンを結合してトランスフォーマーモデルに入力します。
- ☐ ViT では、入力画像をパッチに分割し、各パッチを個別のベクトルに変換する。これらのベクトルに位置情報を付加した後、CLSトークンを追加し、これらの集合をトランスフォーマーへの入力として使用する。
- ☐ ViT は画像を小さな分割画像「パッチ」に変換し、それぞれのパッチをベクトル化して入力ベクトルを生成する。これらのベクトルに対して埋め込み処理を施し、CLSトークンを追加して画像分類を行う。
- ☒ ViT は画像を「パッチ」と呼ばれる小さな分割画像に変換し、それぞれのパッチをベクトルに変換した後、パッチ毎に異なる位置エンコーディングを適用し、単一の大きなベクトルとして結合してCLSトークンを作成する。 ✓

✓ Vision Transformer (ViT) は、画像分類タスクで 사용되는 トランスフォーマーベースのモデルである。ViT には画像をモデルに入力するために「位置埋め込み」という手法を用いる。ViTにおける「位置埋め込み」について、以下のうちから誤っているものを1つ選べ。 *1/1

- ☒ 位置埋め込みは、ViT内でパッチ間の距離を測定し、遠く離れたパッチほど影響力を小さくするために使用される。これにより、遠く離れたパッチは分類にほとんど影響を与えないようになる。 ✓
- ☐ ViT の位置埋め込みは、画像内の各パッチに固有の位置情報を割り当てることで、画像の空間的な構造をモデルに伝える。この手法により、パッチの内容だけでなくその配置も重要な情報として扱われる。
- ☐ ViT では、位置埋め込みによって各パッチの絶対位置情報が加えられ、モデルは画像全体のレイアウトをより正確に解釈することが可能になる。このプロセスは、画像の詳細な理解に不可欠である。
- ☐ 位置埋め込みは、ViT において、各画像パッチの位置情報をモデルに伝えるために使用される。これにより、モデルはパッチ間の相対的な位置関係を理解し、より効果的な画像分類を行うことができる。

✓ IoUは、バウンディングボックスがどれだけ重なっているかを示す指標である。 *1/1

IoUの計算式として、正しいものを以下の中から選べ。

- ☒ 積集合／和集合 ✓
- ☐ 和集合－積集合
- ☐ 積集合＊和集合
- ☐ 和集合／積集合

物体検出タスクでは、物体が存在すると考えられる領域の座標を求め、そのうえで推定した物体領域部分の画像に対して画像分類を行うことになる。物体の候補領域を選択的探索によって求める代表的な物体検出モデルは（ あ ）である。選択的探索は、画像を（ い ）に分割し、色、テクスチャ、サイズ、領域同士の包含関係などの類似度に基づいて、領域を階層的に統合することで候補領域を生成する手法である。なお、（ あ ）では、生成された候補領域のクラス分類に（ う ）が用いられる。

✓ （ あ ）に当てはまる選択肢について、以下のうち最も適切なものを *1/1
1つ選べ。

- ☒ R-CNN
- ☐ Fast R-CNN
- ☐ SSD
- ☐ YOLO



✓ （ い ）に当てはまる選択肢について、以下のうち最も適切なものを *1/1
1つ選べ。

- ☐ 特徴チャンネル
- ☒ 初期領域
- ☐ アンカーボックス
- ☐ クラスラベル



✓ (う) に当てはまる選択肢について、以下のうち最も適切なものを *1/1
1つ選べ。

- ☐ PCA
- ☒ SVM
- ☐ KNN
- ☐ k-means



✗ 次のうち、RoIプーリングを採用していないモデルとして適当なものを1 *0/1
1つ選べ。

- ☐ Faster R-CNN
- ☐ R-CNN
- ☐ 全て採用されている
- ☒ Fast R-CNN



物体検出モデルの (あ) は領域提案ネットワーク (RPN) を使うことで、高速化に成功した。このRPNを学習する際に用いる損失関数は、分類損失と回帰損失の2つの損失に分解できる。分類損失ではアンカーボックスが物体か非物体かについて対数損失を用いて求める。回帰損失ではアンカーボックスの位置を求めるが、この数値はアンカーボックスが (い) のとき損失に加算される。このとき、位置を推定するタスクに利用される損失関数は (う) である。



✓ (あ) に当てはまる選択肢について、以下のうち最も適切なものを *1/1
1つ選べ。

- ☐ R-CNN
- ☐ Fast R-CNN
- ☐ Mask R-CNN
- ☒ Faster R-CNN



✓ (い) に当てはまる選択肢について、以下のうち最も適切なものを *1/1
1つ選べ。

- ☐ 非物体
- ☐ 設定値以上
- ☐ 設定値以下
- ☒ 物体



✓ (う) に当てはまる選択肢について、以下のうち最も適切なものを *1/1
1つ選べ。

- ☐ Cross Entropy損失
- ☒ Smooth L1損失
- ☐ Binary Cross Entropy損失
- ☐ 平均二乗誤差



Fast R-CNNは、画像全体から一度だけ特徴マップを生成し、（ あ ）の候補領域でその特徴マップを再利用することで、R-CNNよりも高速化した。

Faster R-CNNは、（ い ）を用いて候補領域を予測することで、外部の候補領域生成手法を不要にした。Fast R-CNNとFaster R-CNNでは、分類層へ入力する特徴量を固定サイズにするために（ う ）を用いる。

R-CNN、Fast R-CNN、Faster R-CNNのうち、候補領域の生成までニューラルネットワークへ組み込み、検出パイプライン全体を統合したモデルは（ え ）である。

✓ （ あ ）（ え ）に当てはまる組み合わせについて、以下のうち最も *1/1 適切なものを1つ選べ。

- ☐ （あ）一部 （え） Faster R-CNN
- ☐ （あ）全て （え） Fast R-CNN
- ☐ （あ）一部 （え） Fast R-CNN
- ☒ （あ）全て （え） Faster R-CNN



✓ （ い ）に当てはまる選択肢について、以下のうち最も適切なものを *1/1 1つ選べ。

- ☐ PCA
- ☐ RoI
- ☐ SVM
- ☒ RPN



✓ (う) に当てはまる選択肢について、以下のうち最も適切なものを *1/1
1つ選べ。

- ☒ RoIプーリング層
- ☐ Avgプーリング層
- ☐ Maxプーリング層
- ☐ GlobalMaxプーリング層



Faster R-CNNは、領域提案ネットワーク（RPN）と詳細な物体認識を行うFast R-CNNで構成される。RPNは入力特徴マップから物体の候補領域とその物体らしさを出力し、Fast R-CNNはこれらの領域を元に物体の位置とクラスを特定する。RPN内では、特徴マップに対し $n \times n$ 畳み込みを適用し、結果をreg layer（座標予測）とcls layer（物体か背景かの分類）へ入力。ここで、各位置に設定されたk個のアンカーボックスを通じて、4k個の座標値と2k個のクラス分類値が出力される。アンカーボックスは異なる（ あ ）を持ち、交差する正解ボックスとの重なり（ い ）によりラベル付けされる。RPNの損失関数は、分類損失と回帰損失の合計であり、特徴マップの空間サイズを $H \times W$ 、各位置に配置するアンカーボックス数をkとすると、アンカーボックスの総数は（ う ）となる。

RPNを訓練する際に用いる損失関数は、分類損失と回帰損失を組み合わせた以下の式の形で与えられる。ここで、 i はミニバッチ内でのアンカーボックスのインデックス、 p_i はアンカーボックス i が物体である確率、 t_i は予測された座標ベクトル、 $*$ は正解ラベルを意味する符号である。損失関数内の係数（ え ）は、正例のアンカーボックスの場合にのみ、回帰損失が加味されるようにするためのものである。

$$L(\{p_i\}, \{t_i\}) = \frac{1}{N_{cls}} \sum_i L_{cls}(p_i, p_i^*) + \lambda \frac{1}{N_{reg}} \sum_i (\bar{\epsilon}) L_{reg}(t_i, t_i^*)$$



✓ (あ) に当てはまる選択肢について、以下のうち最も適切なものを *1/1
1つ選べ。

- ☐ スケール
- ☐ 回転角度
- ☒ スケールおよびアスペクト比
- ☐ アスペクト比



✓ (い) に当てはまる選択肢について、以下のうち最も適切なものを *1/1
1つ選べ。

- ☒ IoU
- ☐ 内積
- ☐ AUC
- ☐ mAP



✓ (う) に当てはまる選択肢について、以下のうち最も適切なものを *1/1
1つ選べ。

- ☐ $H \times W \times C \times k$
- ☒ $H \times W \times k$
- ☐ $C \times k$
- ☐ k



✓ (え) に当てはまる選択肢について、以下のうち最も適切なものを *1/1
1つ選べ。

$$t_i^*$$

☐ A

$$p_i^*$$

☒ B



$$t_i$$

☐ C

$$p_i$$

☐ D

✓ 次のうち、RoI Alignを採用しているモデルとして適切なものを1つ選べ。 *1/1

☒ Mask R-CNN



☐ Fast R-CNN

☐ R-CNN

☐ Faster R-CNN



セグメンテーションモデルは、全体の情報を統合した特徴量を作りながら、もとなったピクセルの詳細な位置情報を失わないでいるか、という矛盾する要件をいかに満たすかという点で工夫が行われる。

その中で、エンコーダ側で最大値プーリングで採用された値の位置を記録し、デコーダ側でアップサンプリングする際にその位置を利用する手法を採用したモデルとして、SegNetが挙げられる。また、エンコーダで作成した特徴マップをデコーダに伝達し、前層から作成した特徴マップとチャンネル方向に連結することで高い精度を獲得した U-Netがある。また、従来の物体検出モデルである Faster R-CNN にセグメンテーションのブランチを追加することで、セグメンテーションを可能とした（ あ ）というモデルもある。特に（ あ ）は、（ い ）の寄与により物体検出の精度を向上することに成功している。

✓ （ あ ）に当てはまる選択肢について、以下のうち最も適切なものを *1/1
1つ選べ。

- ☐ U-Net
- ☐ SegNet
- ☐ FCN
- ☒ Mask R-CNN



✓ （ い ）に当てはまる選択肢について、以下のうち最も適切なものを *1/1
1つ選べ。

- ☒ マルチタスク学習
- ☐ 転移学習
- ☐ 事前学習
- ☐ 自己教師あり学習



Mask R-CNNでは、候補領域の座標を整数へ丸めることで生じる位置ずれを避けるため、座標を量子化せず、双線形補間によって特徴量を取得する（ あ ）を導入している。

また、Faster R-CNNの分類・バウンディングボックス回帰ブランチに加えて、各インスタンスのマスクを予測する（ い ）を追加している。

✓ （ あ ）に当てはまる選択肢について、以下のうち最も適切なものを *1/1
1つ選べ。

- ☐ Pooling Indices
- ☐ IoU
- ☐ Transpose convolution
- ☒ ROI Align



✓ （ い ）に当てはまる選択肢について、以下のうち最も適切なものを *1/1
1つ選べ。

- ☐ segmentation branch
- ☐ region proposal network
- ☒ mask branch
- ☐ mask segmentation



画像処理のタスクには、「物体検出」とよばれるタスクがある。画像分類タスクでは、画像全体に何が写っているのかを分類するが、物体検出タスクでは、画像の「どこ」に何が写っているかを分類する点が異なる。

物体検出タスクでは、画像の上をバウンディングボックスと呼ばれる矩形領域で物体を囲むことで位置を示す。同一物体に対して複数のバウンディングボックスが検出されてしまうことがある。その際、利用する処理に（ あ ）がある。（あ）では、まず信頼度が最も（ う ）バウンディングボックスを採用し、そのボックスとのIoUが設定値（ い ）ほかのバウンディングボックスを除外する。この処理を、候補がなくなるまで繰り返す。

✓ （ あ ）に当てはまる選択肢について、以下のうち最も適切なものを ^{*}1/1 1つ選べ。

- ☐ Dice
- ☒ NMS
- ☐ MRF
- ☐ SVM



✓ （ い ）（ う ）に当てはまる組み合わせについて、以下のうち最も ^{*}1/1 適切なものを1つ選べ。

- ☐ （い）以上 （う）低い
- ☐ （い）以下 （う）低い
- ☒ （い）以上 （う）高い
- ☐ （い）以下 （う）高い



✕ 初代YOLOに関する記述として、誤っているものを1つ選べ。 *

0/1

- ☐ ベースネットワークとしてVGG16をそのまま採用している。
- ☐ 最終出力層には線形活性化を使用し、それ以外の層では主にLeaky ReLUを使用する。
- ☐ 入力画像をグリッドに分割し、各グリッドセルからバウンディングボックスやクラス確率を予測する。
- ☒ 物体候補領域の生成とクラス分類を、単一のニューラルネットワークで一度に 行う。 ✕

高速な物体検出モデルとしてシングルショット系とよばれる物体候補の推定と分類を同時に行うモデルが存在する。シングルショット系のモデルとしては、入力画像を複数の小領域に分割し、各小領域ごとにクラス分類とバウンディングボックスの位置や大きさなどの回帰を行う（ あ ）や、大きさの異なる複数の特徴マップを使ってクラス分類やバウンディングボックス回帰を行う（ い ）がある。

（ あ ）は、グリッドあたりのバウンディングボックスの最大予測数をあらかじめハイパーパラメータとして設定しておく必要がある。最大予測数を大きくすると計算量が増えていくため、速度を維持することを考えると、（ う ）のような画像を不得意としている。（ あ ）では、最終出力層に（ え ）を使用し、それ以外の層では主に（ お ）を使用する。

✓ （ あ ）に当てはまる選択肢について、以下のうち最も適切なものを *1/1 1つ選べ。

- ☐ SSD
- ☒ YOLO
- ☐ ResNet
- ☐ U-Net



✓ (い) に当てはまる選択肢について、以下のうち最も適切なものを *1/1
1つ選べ。

- ☐ YOLO
- ☒ SSD
- ☐ ResNet
- ☐ U-Net



✓ (う) に当てはまる選択肢について、以下のうち最も適切なものを *1/1
1つ選べ。

- ☐ 物体同士が離れて存在する
- ☐ 同じクラスの物体が存在する
- ☒ 複数の物体が密集して存在している
- ☐ 大きさが異なる物体同士が存在している



✓ (え) に当てはまる選択肢について、以下のうち最も適切なものを *1/1
1つ選べ。

- ☐ Tanh
- ☐ Sigmoid
- ☐ Leaky ReLU
- ☒ 線形活性化



✓ (お) に当てはまる選択肢について、以下のうち最も適切なものを *1/1
1つ選べ。

☐ 線形活性化

☒ Leaky ReLU



☐ Sigmoid

☐ Tanh

物体検出タスクは、リアルタイムで検出できるかどうかで実用性の観点からみると、大きな差がある。高速に処理するために、物体領域候補の推定と分類を同時に行うシングルショット系のモデルが開発されている。

シングルショット系物体検出モデルの中で、(あ) は様々なアスペクト比の特徴マップを用いる点に特徴がある。(あ) は、バウンディングボックスを直接予測するのではなく、あらかじめ用意しておいたデフォルトボックスと呼ばれるボックスを変形させるパラメータを学習することで物体検出を行う。

(あ) では学習のための工夫も行われている。典型的な画像の多くは背景によって占められており、そのため、提案されたバウンディングボックスのほとんどが背景ボックス（ネガティブ）となる。そのまま損失を与えると学習が安定しないため、背景のバウンディングボックスを損失に与える量を制限する手法が存在する。特に(あ) でも採用された、物体に対するバウンディングボックスと背景に対するバウンディングボックスの比率を最大でも3：1にして、信頼度が降順になるようにソートして利用するボックスを上からピックアップしていく手法を(い) と呼ぶ。



✓ (あ) に当てはまる選択肢について、以下のうち最も適切なものを *1/1
1つ選べ。

- ☐ YOLO
- ☒ SSD
- ☐ Fast R-CNN
- ☐ Faster R-CNN



✗ (い) に当てはまる選択肢について、以下のうち最も適切なものを *0/1
1つ選べ。

- ☒ マルチボックスマッチング
- ☐ ハードネガティブマイニング
- ☐ スライディングウィンドウ
- ☐ アップサンプリング



✓ SSDの特徴として、誤っているものを以下の選択肢から1つ選べ。 * 1/1

- ☐ 空間解像度の高い特徴マップでは比較的小さな物体を、空間解像度の低い特徴マップでは比較的大きな物体を検出する。
- ☐ ハードネガティブマイニングによって、物体ラベルが存在するバウンディングボックスと存在しないバウンディングボックスの比率を調整している。
- ☐ 1つのネットワーク内の異なる層から得られる、複数の解像度の特徴マップを利用して物体を検出する。
- ☒ YOLOとは異なり、ベースとなるネットワークにVGGを採用していない。



✓ FCOSのようなアンカーフリー物体検出手法に関する記述として、誤って ^{*}1/1 いるものを1つ選べ。

- ☐ 学習時に、事前定義したアンカーボックスと正解ボックスとのIoUを計算して対応付ける処理を省略できる。
- ☐ あらかじめ複数のアンカーボックスのスケールやアスペクト比を設定する必要がない。
- ☐ 特徴マップ上の各位置から、クラスやバウンディングボックスまでの距離を直接予測する。
- ☒ アンカーボックスを用いないため、正例と負例の割り当てを考慮する必要がなく、どのようなデータセットでも精度が必ず向上する。 ✓

✓ FCOSの独自の要素であるセンターネスについて、以下のうち誤って ^{*}1/1 る選択肢を1つ選べ。

- ☐ 低品質のバウンディングボックスを抑えるための項目である。
- ☐ 特徴マップ上の位置から正解バウンディングボックスの上下左右の辺までの距離を基に、その位置が物体中心にどの程度近いかを表す指標である。
- ☐ 学習の際にはセンターネス損失の数値をBinary Cross Entropy損失で計算し、分類の損失とバウンディングボックスの損失を総合して逆伝播する。
- ☒ 前処理の段階で計算が行われるため、損失関数には含まれない。 ✓

セグメンテーションモデルであるFCNの成功に触発され、2019年に豪アデレード大学が発表した物体検出モデルとして、FCOSがある。物体検出もピクセル単位で行うことができないかという主眼から開発された。アンカーフリー（アンカーボックスを使わない）の検出モデルとして特徴がある。

✓ FCOSの特徴について正しい記述を選べ。 *

1/1

- ☐ RPNによって候補領域を生成した後、それぞれの候補領域を分類する。
- ☐ 画像全体を1つの特徴ベクトルへ変換し、その特徴ベクトルから1個のバウンディングボックスだけを出力する。
- ☒ センターネスを導入し、物体中心から離れた位置で生成される低品質なバウンディングボックスのスコアを抑制する。 ✓
- ☐ あらかじめ設定した複数のアンカーボックスのスケールとアスペクト比を基に予測する。

✓ アンカーフリー手法による改善点として誤っているものを選べ。 *

1/1

- ☐ アンカーボックスのスケールやアスペクト比を、データセットごとに事前設定する必要がない。
- ☒ 学習時にデータ内のポジティブサンプル数とネガティブサンプル数に影響をうけない。 ✓
- ☐ 各位置で複数のアンカーボックスを評価する処理が不要となり、検出器の構成を単純化できる。
- ☐ アンカーボックスに対するハイパーパラメータ（アスペクト比を設定するなど）の調整が不要になった。



- ✓ 画像認識におけるタスクの1つとしてセグメンテーションタスクがある。これは入力画像に対して、画像を構成する各ピクセルについて分類を行いラベルを付与するタスクである。セグメンテーションタスクにおける代表的なモデルの1つであるFCN（Fully Convolutional Network）に関する記述として、最も適切なものを1つ選べ。 *1/1
- ☐ FCNのスキップ接続は、RNNの再帰処理をそのまま画像処理へ適用したものである。
- ☐ アップサンプリングに用いる転置畳み込み層のパラメータは固定されており、学習によって更新されない。
- ☐ 入力画像全体に対して、必ず1つのクラスラベルだけを出力するモデルである。
- ☒ 分類用CNNの全結合層を畳み込み層へ置き換えることで、任意サイズの入力画像に対して空間的な予測結果を出力できる。 ✓

- ✓ 物体検出タスクでは、あくまで矩形領域によって物体を検出するため、物体以外のものも含まれてしまうという問題が存在する。物体の形状をより詳細に捉えるため、画像内の各ピクセルを分類し、物体が占める領域を推定するセグメンテーションタスクがある。セグメンテーションでは画像に対しピクセル単位でクラス分類を行うことで画像内の物体の領域を明らかにする。特にセグメンテーションタスクの中でも、個々の物体ごとに別のラベルを付与するタスクを（ あ ）セグメンテーションと呼ぶ。 *1/1
- （ あ ）に当てはまる選択肢について、以下のうち最も適切なものを1つ選べ。

- ☐ ピクセル
- ☒ インスタンス ✓
- ☐ セマンティック
- ☐ オブジェクト

セグメンテーションタスクは、ピクセル単位での分類を行うため、画像分類や物体検出よりも難易度の高いタスクとなっている。そのため、セグメンテーションを可能とするための専用のモデルの開発が行われている。

セグメンテーションタスクの代表的なモデルにFCNがある。FCNは、分類用CNNの（ あ ）を畳み込み層へ置き換えることで、異なるサイズの入力画像に対応できるようにした。

また、ピクセル単位の予測結果を得るために、一度小さくなった特徴マップを拡大する（ い ）が用いられる。

さらに、FCN以降のさまざまなセグメンテーションモデルでは、特徴マップの解像度を大きく低下させずに受容野を広げる方法として、間隔を空けて畳み込みを行う（ う ）が用いられることがある。

✓ （ あ ）に当てはまる選択肢について、以下のうち最も適切なものを *1/1
1つ選べ。

- ☐ パディング
- ☒ 全結合層
- ☐ プーリング層
- ☐ 畳み込み層



✓ （ い ）に当てはまる選択肢について、以下のうち最も適切なものを *1/1
1つ選べ。

- ☐ コーザル畳み込み
- ☒ 転置畳み込み
- ☐ ダイレイト畳み込み
- ☐ グラフ畳み込み



× (う) に当てはまる選択肢について、以下のうち最も適切なものを *0/1
1つ選べ。

- ☐ ダイレイト畳み込み
- ☐ コーザル畳み込み
- ☒ グラフ畳み込み
- ☐ 転置畳み込み

×

✓ セグメンテーションタスクに対する代表的な手法として U-Net がある。 *1/1
U-Net は畳み込みと転置畳み込みを中心に構成された (あ) である。U-Net における特徴としてスキップ接続の他に (い) が挙げられる。

(あ) (い) に当てはまる組み合わせについて、以下のうちから適切なものを1つ選べ。

- ☐ (あ) Decoder-only 型のモデル (い) デコーダ内において転置畳み込みの間に畳み込みを行うこと
- ☐ (あ) Decoder-only 型のモデル (い) 最後の出力を除いて、チャンネル方向の畳み込み・転置畳み込みのみを配置していること
- ☐ (あ) Encoder-Decoder 型のモデル (い) 最後の出力を除いて、チャンネル方向の畳み込み・転置畳み込みのみを配置していること
- ☒ (あ) Encoder-Decoder 型のモデル (い) デコーダ内において転置畳み込みの間に畳み込みを行うこと ✓

- ✓ エンコーダ側で最大値プーリングで採用された値の位置を記録し、デコーダ側でアップサンプリングする際にその位置を利用する手法を採用したモデルとして SegNetが挙げられる。また、エンコーダで作成した特徴マップをデコーダに伝達し、前層から作成した特徴マップとチャンネル方向に連結することで高い精度を獲得した（ あ ）がある。また、従来の物体検出モデルである Faster R-CNN にセグメンテーションのブランチを追加することで、セグメンテーションを可能としたMask R-CNNというモデルもある。 *1/1

（ あ ）に当てはまる選択肢について、以下のうち最も適切なものを1つ選べ。

- ☐ SegNet
- ☐ FCN
- ☒ U-Net
- ☐ Mask R-CNN



このフォームは デロイト トーマツ ディープスクエア株式会社 内部で作成されました。
このフォームが不審だと思われる場合 [報告](#)

Google フォーム



