

修了試験B-3

合計点 39/44 点 ?

合格点 85%以上 (38以上/44)

0 / 0 ポイント

受験者情報の登録

登録メールアドレス *

htanaka@777.so-net.jp

御名前 *

田中 秀伯

修了試験問題

39 / 44 ポイント

- ✓ 強化学習の手法として、動的計画法、モンテカルロ法、TD学習、TRPO *1/1
などがある。(あ) は、目標の価値と現在の価値のずれを修正していくことによって、価値関数を推定する方法である。(あ) の代表的な手法として、SarsaとQ学習がある。

(あ) の選択肢として最も適切なものを選び。

- ☒ TD学習
- ☐ モンテカルロ法
- ☐ 動的計画法
- ☐ TRPO



✓ Q学習に関する記述として、誤っているものを1つ選べ。 *

1/1

- ☐ Q学習では、次状態において取り得る行動のうち、最大の行動価値を更新目標の計算に利用する。
- ☐ Q学習は、行動を選択する方策と、更新目標を定める方策が異なり得るオフポリシー型の手法である。
- ☒ Q学習では、次状態で実際に選択した行動の価値を更新目標の計算に利用する。 ✓
- ☐ 学習に必要な遷移データを収集するため、 ϵ -greedy法などを用いて探索を行うことがある。



- ✓ 方策勾配に基づくアルゴリズムにおいては方策勾配の定理により、目的関数 $J(\theta)$ の θ に関する勾配を以下のように計算できる。(あ) に当てはまるものとして、適切なものを1つ選べ。 *1/1

$$\nabla_{\theta} J(\theta) = E_{\pi_{\theta}}[(\text{あ})]$$

$$\nabla_{\theta} \log(\pi_{\theta}(a|s)) Q^{\pi}(s, a)$$

☒ A



$$\nabla_{\theta} \pi_{\theta}(a|s) Q^{\pi}(s, a)$$

☐ B

$$\frac{\nabla_{\theta} \pi_{\theta}(a|s)}{Q^{\pi}(s, a)}$$

☐ C

$$\frac{Q^{\pi}(s, a)}{\nabla_{\theta} \pi_{\theta}(a|s)}$$

☐ D



- ✓ 「入力データが時系列データであり、入力データ間に独立性が無い」という問題に対してDQNでは（ あ ）を適用した。（ あ ）において、エージェントが経験した状態・行動・報酬・遷移先は一旦メモリに保存される。損失の計算を行う際にはメモリに保存したデータからランダムにサンプリングを行う。 *1/1

（ あ ） に当てはまる用語として、適切なものを1つ選べ。

- ☐ Target Q-Network
- ☒ Experience Replay ✓
- ☐ 報酬のクリッピング
- ☐ REINFORCEアルゴリズム

- ✓ Qネットワークの更新に伴って、学習目標となるTD目標も連続的に変化すると、学習が不安定になりやすい。この問題を緩和するため、DQNでは（ い ）を導入した。 *1/1

（ い ）では、TD目標の計算に使用するネットワークのパラメータを一定期間固定し、一定間隔でオンラインネットワークのパラメータを反映する。

（ い ） に当てはまる用語として、適切なものを1つ選べ。

- ☐ REINFORCEアルゴリズム
- ☒ Target Q-Network ✓
- ☐ Experience Replay
- ☐ 報酬のクリッピング

- ✓ 元のDQNでは、正の報酬を+1、負の報酬を-1、報酬がない場合を0として扱う（う）が用いられた。（う）は、ゲームごとに異なる報酬スケールの影響を抑え、学習を安定させやすくする一方、報酬の大きさに関する情報が失われるという欠点がある。 *1/1

（う）に当てはまる用語として、適切なものを1つ選べ。

- ☒ 報酬のクリッピング ✓
- ☐ Experience Replay
- ☐ Target Q-Network
- ☐ REINFORCEアルゴリズム

- ✓ 強化学習の1つであるQ学習に深層学習を適用した手法としてDQNがある。強化学習において、深層ニューラルネットワークをQ関数や方策関数の表現に使用する理由について、以下のうちから適切なものを1つ選べ。 *1/1

- ☒ 複雑な状態や行動空間を効率的に学習し、高い汎化能力を示すため。 ✓
- ☐ 常に正確な予測を行い、学習の収束速度を加速させるため。
- ☐ 計算コストが低く、非線形問題に対して最適な解を提供するため。
- ☐ 任意の状態に対して最適な行動を直接出力でき、学習プロセスが簡略化されるため。

2016年にGoogle傘下のDeepMind社から発表された強化学習モデルに、A3Cがある。方策反復ベースの深層強化学習モデルとして代表的なアルゴリズムのひとつである。

A3Cとは、Advantage学習、Actor-Critic、Asynchronous（非同期）の3つを融合させたものからとっている。

A3Cでは、複数のActor-Learnerがサンプルを（ あ ）に生成し、それぞれが計算した勾配を共有パラメータへ（ い ）に反映する。

Experience Replayを使用せず、各Actorが時系列に沿って環境と相互作用するため、（ う ）を組み込んだモデルも構成できる。

✓ （ あ ） と （ い ） を組み合わせた選択肢として、適切なものを1 ^{*1/1} つ選べ。

- ☐ （あ）直列 （い）非同期
- ☐ （あ）直列 （い）同期
- ☐ （あ）並列 （い）同期
- ☒ （あ）並列 （い）非同期



✓ （ う ） の選択肢として、適切なものを1つ選べ。 *

1/1

- ☐ CNN
- ☐ GAN
- ☒ RNN
- ☐ XAI



✕ Advantage関数は、ある状態において特定の行動を選ぶことが、その状態の基準となる価値と比べてどの程度有利かを表す。Advantage関数に関する記述として、誤っているものを1つ選べ。 *0/1

- ☐ Advantageが正である場合、その行動は基準となる状態価値よりも高い価値を持つことを示す。
- ☐ Actor-Criticでは、Advantageの推定値を方策勾配の重みとして利用することがある。
- ☐ Advantage関数とは、Q関数を必ず2ステップ以上先まで進めて更新する手法を指す。
- ☒ Advantage関数は、一般に行動価値関数 $Q(s,a)$ から状態価値関数 $V(s)$ を差し引いて表される。 ✕

✓ Actor-Critic に関連する説明文のうち、誤っている説明文を1つ選べ。 * 1/1

- ☒ Actorは価値関数を学習し、Criticは行動を選択する方策を学習する。 ✓
- ☐ Actorは、状態に応じてどの行動を選択するかを表す方策を学習する。
- ☐ Actor-Criticは、方策を学習する方策ベースの手法と、価値関数を推定する価値ベースの手法を組み合わせたものである。
- ☐ Criticは、状態価値や行動価値などを推定し、Actorによる方策の更新を評価する。

- ✓ 強化学習では、エージェントが各タイムステップにおいて与えられた環境のもと行動を選択し、報酬と次の状態を得る。強化学習の手法としてDQNとA3Cがあり、それぞれはQ学習と方策勾配法を基礎にした手法である。 *1/1

DQNとA3Cに関連する説明文について、以下のうち適切なものを1つ選べ。

- ☐ A3CはExperience Replayを使用し、DQNは分散並列処理によって学習を行う。
- ☐ DQNはExperience Replayを利用しないが、A3Cは分散並列処理を用いて効率的な学習を行う。
- ☒ DQNではExperience Replayを用いて安定した学習を実現し、A3Cでは分散並列処理によって効率的な学習が可能になる。 ✓
- ☐ DQNとA3Cはともに方策勾配法を基礎にしており、Experience Replayと分散並列処理の両方を利用する。

- ✓ 転移学習とは、あるデータやタスクで学習したモデルの知識を、別のデータやタスクへ活用する方法である。 *1/1

学習済みモデルの特徴抽出部分を固定し、新しい出力層だけを学習する方法がある一方、学習済みモデルの一部または全部のパラメータを新しいタスクに合わせて更新する（ あ ）という方法もある。

（ あ ）に当てはまる語句として、適切なものを1つ選べ。

- ☐ 事前学習
- ☐ マルチタスク学習
- ☒ ファインチューニング ✓
- ☐ エンドツーエンド学習

✓ 転移学習、ワンショット学習、ゼロショット学習に関する記述として、*1/1
誤っているものを1つ選べ。

- ☐ ゼロショット学習では、新しいクラスのラベル付き学習事例を直接使用せず、属性や言語情報などを利用して識別する。
- ☐ 転移学習では、あるデータやタスクで獲得した知識を別のデータやタスクへ活用する。
- ☒ ワンショット学習とゼロショット学習は、どちらも新しいクラスのラベル付き事例を一切使用しない。 ✓
- ☐ ワンショット学習では、新しいクラスについて1件のラベル付き事例を利用して識別や学習を行う。

✓ ドメインシフトの影響を緩和するために一般的に用いられるアプローチ *1/1
について適切なものを1つ選べ。

- ☐ 特徴選択（Feature Selection）を用いて、データセットから不要な特徴を削除する。
- ☐ ハイパーパラメータチューニングを通じてモデルの複雑さを調整する。
- ☒ データ拡張（Data Augmentation）やドメイン適応手法を用いて、異なるドメイン間のギャップを縮める。 ✓
- ☐ バッチサイズを増やして、訓練プロセスを安定させる。

- ✓ ドメイン適応は、ソースドメインで学習したモデルを異なるターゲットドメインへ適用するため、両ドメイン間の（ あ ）の違いを緩和する方法である。 *1/1

特に、ターゲットドメインのラベル付きデータが少ない、または存在しない一方で、ラベルなしターゲットデータを利用できる場合に用いられる。

（ あ ）に当てはまる語句として、適切なものを1つ選べ。

- ☐ モデルの複雑さ
- ☒ データ分布
- ☐ データ量
- ☐ 訓練時間



以下のコードを踏まえて、設問に答えよ。

```
from torchvision import datasets, models, transforms

# 画像の変換処理を定義
transform = transforms.Compose(
    [transforms.ToTensor(), # 画像をテンソルに変換
     transforms.Normalize((0.5, 0.5, 0.5), (0.5, 0.5, 0.5))]) # 画像を正規化

# CIFAR-10の訓練データをダウンロードして変換
trainset = torchvision.datasets.CIFAR10(root='./data', train=True,
                                         download=True, transform=transform)
trainloader = torch.utils.data.DataLoader(trainset, batch_size=4,
                                         shuffle=True, num_workers=2)

# CIFAR-10のテストデータをダウンロードして変換
testset = torchvision.datasets.CIFAR10(root='./data', train=False,
                                         download=True, transform=transform)
testloader = torch.utils.data.DataLoader(testset, batch_size=4,
                                         shuffle=False, num_workers=2)

# クラスラベルの定義
classes = ('plane', 'car', 'bird', 'cat',
           'deer', 'dog', 'frog', 'horse', 'ship', 'truck')

# VGG-16モデルのインスタンスを生成
net = models.vgg16(weights='IMAGENET1K_V1')
net.eval()

# モデルのネットワーク構成を出力
print(net)
```

以下のコードを踏まえて、設問に答えよ。

```
VGG(
  (features): Sequential(
    (0): Conv2d(3, 64, kernel_size=(3, 3), stride=(1, 1), padding=(1, 1))
    (1): ReLU(inplace)
    (2): Conv2d(64, 64, kernel_size=(3, 3), stride=(1, 1), padding=(1, 1))
    (3): ReLU(inplace)
    (4): MaxPool2d(kernel_size=2, stride=2, padding=0, dilation=1, ceil_mode=False)
    (5): Conv2d(64, 128, kernel_size=(3, 3), stride=(1, 1), padding=(1, 1))
    (6): ReLU(inplace)
    ...
    (28): Conv2d(512, 512, kernel_size=(3, 3), stride=(1, 1), padding=(1, 1))
    (29): ReLU(inplace)
    (30): MaxPool2d(kernel_size=2, stride=2, padding=0, dilation=1, ceil_mode=False)
  )
  (classifier): Sequential(
    (0): Linear(in_features=25088, out_features=4096, bias=True)
    (1): ReLU(inplace)
    (2): Dropout(p=0.5)
    (3): Linear(in_features=4096, out_features=4096, bias=True)
    (4): ReLU(inplace)
    (5): Dropout(p=0.5)
    (6): Linear(in_features=4096, out_features=1000, bias=True)
  )
)
```

図 1 : VGG出力結果

```
net.〈あ〉 = nn.Linear(in_features=4096, out_features=〈い〉)
```

コード 2 : 転移学習の調整

✕ コード 1 のプログラムは、転移学習を行う為の事前準備である。コード *0/1
1 のプログラムと図 1 のネットワーク構成図をヒントにして、コード 2
のプログラムを転移学習を行うプログラムとして完成させたい。

(あ) に当てはまるものとして、適切な選択肢を1つ選べ。

- ☐ classifier[6]
- ☐ features[30]
- ☐ features[0]
- ☒ classifier[0]

✕

✓ コード 1 のプログラムは、転移学習を行う為の事前準備である。コード *1/1
1 のプログラムと図 1 のネットワーク構成図をヒントにして、コード 2
のプログラムを転移学習を行うプログラムとして完成させたい。

(い) に当てはまる値として、適切なものを1つ選べ。

- ☐ 4096
- ☐ 512
- ☒ 10
- ☐ 128

✓

✓ 半教師あり学習について、以下のうち誤っている選択肢を1つ選べ。 * 1/1

- ☐ 一貫性正則化では、同じデータへ異なる摂動を加えた場合でも、モデルの予測が大きく変化しないように学習する。
- ☐ Self-Trainingでは、ラベル付きデータで学習した分類器を用いてラベルなしデータへ疑似ラベルを付与し、信頼度の高いデータを学習へ追加する。
- ☒ Self-Trainingでは、ラベル付きデータで学習した分類器を用いてラベルなしデータを分類するが、その予測結果は以後の学習には利用しない。 ✓
- ☐ Co-Trainingでは、異なる特徴の見方などを利用する複数の分類器が、ラベルなしデータへの予測結果を相互に利用して学習する。

✓ 自己教師あり学習の一環としての Contrastive Learning では、2つのデータポイントが使用される。この手法の主な目的は、データポイントが表す特徴を学習することにあるが、具体的にどのようなプロセスを通じてこの目的を達成するかについて、適切なものを以下のうちから1つ選べ。 *1/1

- ☐ データセット内の異常なデータポイントを識別し、それらを除外することで、データセットの品質を向上させる。
- ☒ 同一のデータから生成した異なるビューなど、意味的に対応する正例ペアの表現を近づけ、対応しないデータの表現を遠ざけることで、識別に有用な特徴表現を学習する。 ✓
- ☐ 似たようなデータポイントを集めて、クラスタリングアルゴリズムを用いてデータセットを再構築する。
- ☐ データセット内のすべての画像にラベルを手動で付け、教師あり学習アルゴリズムを訓練する。



- ✓ 半教師あり学習は、教師あり学習と違った手法でモデルの訓練を行う。 *1/1

半教師あり学習の説明文について、以下のうちから適切なものを1つ選べ。

- ☐ 疑似ラベル手法は、教師なしデータに対して仮のラベルを付与し、そのデータを使ってモデルを再訓練する。しかし、この方法ではラベルなしデータの全てにラベルを付ける必要がある。
- ☐ 半教師あり学習では、教師ありデータのみを使用し、一致性正則化によってモデルの予測を安定させる。教師なしデータは、モデルの性能を評価するためにのみ使用される。
- ☒ 半教師あり学習は、限られた教師ありデータと大量の教師なしデータを用い、モデルの学習を行う。手法には一致性正則化、疑似ラベルなどがあり、これらはモデルの予測精度を高めるのに役立つ。 ✓
- ☐ 半教師あり分類学習では、最初に教師ありデータを使用して分類器を作成し、その後教師なしデータを用いてクラスタリングを行う。クラスタリングの結果を利用して、教師ありデータのラベル付けを改善する。

- ✓ 自己教師あり学習は、ラベルなしのデータから自動的に学習を進める手法であり、ラベル付けのコストを削減しつつ、データの本質的な特徴を学習することが可能である。この手法の適用例として、Contrastive Learningがある。 *1/1

自己教師あり学習の説明文について、以下のうちから適切なものを1つ選べ。

- ☐ 自己教師あり学習では、モデルが自動的にラベルを生成し、それを用いて常に100%の精度で学習を進めることができる。
- ☒ Contrastive Learningを用いた自己教師あり学習では、対象物の本質的な特徴を理解するために、同じかどうかという問いを通じてデータを分析する。 ✓
- ☐ 自己教師あり学習は、常にラベル付けされたデータを必要とし、主に類似性に基づいてデータを分類する。
- ☐ 自己教師あり学習は、データのラベル付けが完全な場合にのみ有効で、一般的には教師あり学習より精度が低いとされている。



- ✓ 表現学習は機械学習の一分野である。深層学習における表現学習は、*1/1多層のネットワークを利用してより意味のある抽象的な特徴表現を学習することで、深層学習の予測精度などを大幅に向上することができる。

表現学習における説明文について、以下のうちから誤っているものを1つ選べ。

- ☐ 表現の共有は複数のモダリティやドメインにまたがる場合に有効であり、汎用性のある抽象的な有益情報を獲得することが目的である。
- ☐ 表現学習は機械学習において特徴を学習し、それを使用して広汎なタスクを行うことができるようにする手法である。
- ☒ 表現学習は生データから特徴を自動的に発見する手法であるが、これは主にテキストデータにのみ適用可能であり、画像や音声データには適用できない。 ✓
- ☐ 画像処理における表現学習は、ピクセルレベルの情報に固執せず、異なるオブジェクトを区別するのに十分な抽象的な特徴のみをエンコードすることを目指している。

- ✓ Triplet Lossは、基準となる画像 x_i^a (anchor) と同じ人物・物体 ^{*1/1} の画像 x_i^p (positive) との特徴空間上の距離が、異なる人物・物体の画像 x_i^n (negative) との距離よりも、少なくともマージン α だけ小さくなるように学習する手法である。

ここで、 f を入力画像から特徴ベクトルを得るための埋め込み関数とする。この関係を表す式として、適切なものを1つ選べ。

$$\|f(x_i^a) - f(x_i^p)\|_2^2 + \alpha < \|f(x_i^a) - f(x_i^n)\|_2^2$$

☒ A



$$\|f(x_i^a) - f(x_i^p)\|_1^2 < \|f(x_i^a) - f(x_i^n)\|_1^2 + \alpha$$

☐ B

$$\|f(x_i^a) - f(x_i^n)\|_2^2 + \alpha < \|f(x_i^a) - f(x_i^p)\|_2^2$$

☐ C

$$\|f(x_i^a) - f(x_i^n)\|_1^2 + \alpha < \|f(x_i^a) - f(x_i^p)\|_1^2$$

☐ D

メトリックラーニング（距離学習）とは、サンプルを別空間に埋め込み、サンプルとの距離 metric に基づいて類似度を判定できるように学習する手法のことである。

メトリックラーニングは、同じクラスのサンプル間の距離は小さくし異なるクラスのサンプル間の距離を大きくすることで判別を可能とする。直接的にサンプル同士の距離をロスとして利用するアプローチと、同クラスのサンプル間の距離を短縮するような特徴量とそれに対応するクラスの中心位置との距離を利用する Softmax を用いたアプローチが存在する。

✓ メトリックラーニングの代表的な利用例として、最も適切でないものを1 *1/1
つ選べ。

- ☒ 物体検出
- ☐ 画像検索
- ☐ 顔認識
- ☐ 異常検知



✓ 「直接的にサンプル同士の距離をロスとして利用するアプローチ」に当 *1/1
てはまる手法を1つ選べ。

- ☒ SiameseNet
- ☐ SphereFace
- ☐ Center loss
- ☐ ArcFace



距離学習の代表的なモデルのひとつに、Siamese neural network(SiameseNet)がある。同じパラメータと重みを共有する複数個のニューラルネットワークを用意し、二つの異なる入力から出力されたもの同士を比べることで、入力データの関係性を測定する。

contrastive loss（対照損失）が損失関数として利用されるが、contrastive lossが抱えている問題を改良したTripletLossなども発表されている。

✓ SiameseNet について一般的に誤っているものを1つ選べ。 * 1/1

- ☐ 学習中に重みを共有することで学習させるパラメータが比較的少なくすむ。
- ☐ One-shot タスクや Few-shot タスクに対して性能の向上が見込める。
- ☒ クラスの数が少なく、各クラスのデータが多い場合に有効に働く。 ✓
- ☐ 距離的な意味表現を学習するため、比較的少量の学習データでもうまくいく。

✓ Contrastive loss について一般的に誤っているものを1つ選べ。 * 1/1

- ☒ Contrastive Lossでは、ユークリッド距離以外の距離や類似度を利用することはできない。 ✓
- ☐ 正例ペアの表現を近づけ、負例ペアについては一定のマージン以上離すように学習する。
- ☐ 埋め込み空間上におけるデータ間の距離や類似度を利用して損失を計算する。
- ☐ Hadsellらによって2006年に発表された距離学習の損失関数として知られている。

✕ Triplet loss について一般的に誤っているものを1つ選べ。 *

0/1

- ☒ AnchorとPositiveの距離を、AnchorとNegativeの距離よりも一定のマージン分だけ小さくすることを目指す。 ✕
- ☐ Triplet LossではNegativeを使用せず、AnchorとPositiveの2つだけで損失を計算する。
- ☐ Tripletの候補数が多いため、学習時には適切なTriplet miningやサンプリングが重要になる。
- ☐ Anchor、Positive、Negativeの3つのデータを1組として扱う。



- ✓ XAIはExplainable AI（説明可能なAI）のことで、AIが導き出した結果の背景にある理由（プロセス）を明らかにしようとする取り組みやそのモデルのことである。 *1/1

XAIの技術として、代表的なものに（ あ ）、LIME、SHAPなどがある。

（ あ ）とは、クラス分類予測をしたときに、モデルが重要視した箇所を可視化する技術で、CAMの技術を汎用化したものである。

LIMEは、説明対象となる入力の周辺でデータを生成し、元のモデルの予測結果を利用して、局所的で解釈可能なモデルを学習する手法である。元のモデルの内部構造を直接利用しないモデル非依存型の手法だが、説明の内容はサンプリング方法や各種設定の影響を受ける。

SHAPは、ゲーム理論のShapley値に基づいて、特定の予測に対する各特徴量の寄与を算出する説明手法である。加法的特徴量寄与法を統一的に整理し、局所的精度、欠落性、一貫性などの性質を満たす特徴量寄与を求める。

（ あ ）に当てはまる選択肢について、以下から1つ選べ。

- ☐ SHAP
- ☐ LIME
- ☐ MAML
- ☒ Grad-CAM



✓ Explainable AI (XAI) は、AIの判断プロセスを人間が理解可能にする技術や研究分野です。XAIの説明文について、以下のうちから正しいものを1つ選べ。 *1/1

- ☒ XAIでは、Grad-CAM、LIMEなどのツールが、AIの意思決定プロセスの透明化に使用される。 ✓
- ☐ XAIは、機械学習モデルのトレーニング時間を短縮することに重点を置いている。
- ☐ XAIの技術は、SHAPなどのニューラルネットワークを使用しない古典的な機械学習アルゴリズムに焦点を当てている。
- ☐ XAIの研究は、AIの自律性を高めることを主な目的としている。

✕ 2017年にIEEEで発表された、クラス分類予測をしたときにモデルが重要視した箇所を可視化する技術として、Grad-CAMがある。Grad-CAMはCAMの技術を汎用化したものである。 *0/1

Grad-CAMにおける説明文として以下のうちから誤っている選択肢を1つ選べ。


- ☐ Grad-CAMは、ネットワーク内のすべての層の勾配を必ず同時に利用し、それらの影響を一つのヒートマップへ統合する。
- ☐ Grad-CAMは、通常のCAM (Class Activation Mapping) で使用される順伝播時のグローバルアベレージプーリング層の重みの代わりに、逆伝播時の勾配を用いて可視化を行う。
- ☒ Grad-CAMは、対象クラスのスコアに対する、選択した畳み込み層の特徴マップの勾配を重みとして利用し、予測に寄与した領域を粗く可視化する。 ✕
- ☐ Grad-CAMは、勾配を利用することで、グローバルアベレージプーリング層を含まないCNNモデルにも適用可能である。これにより、さまざまな種類のCNNアーキテクチャでの可視化が可能になる。

- ✓ CNNなどを用いた画像分類で予測精度が上がらず、その原因が分からない場合がある。 *1/1

そのようなときに（ あ ）を用いて、画像分類の根拠となる部分をモデルがどう判断しているのか確かめることでモデルの問題点がある場合がある。

下図の写真では以下の結果になったが、この結果からこのモデルは（ い ）を重要な情報として認識していることが分かった。

（ あ ）（ い ）に当てはまる組み合わせとして適切なものを1つ選べ。



- ☒ （あ） Grad-CAM （い） 猫 ✓
- ☐ （あ） Grad-CAM （い） 犬
- ☐ （あ） Guided Backprop （い） 犬
- ☐ （あ） Guided Backprop （い） 猫

以下のコードを踏まえて、設問に答えよ。

```
from pytorch_grad_cam import GradCAM, HiResCAM, ScoreCAM, GradCAMPlusPlus,
AblationCAM, XGradCAM, EigenCAM, FullGrad
from pytorch_grad_cam.utils.model_targets import ClassifierOutputTarget
from pytorch_grad_cam.utils.image import show_cam_on_image

from torchvision.transforms import v2
from torchvision.models import vgg16

# 事前学習済みのVGG16モデルをロードします
model = vgg16(weights='IMAGENET1K_V1')
model = model.eval()

target_layer = (あ)

# 画像を読み込み、色の順番をBGRからRGBに変更
rgb_img = cv2.imread('examples/both.png', 1)[:, :, ::-1]
rgb_img = np.float32(rgb_img) / 255

# 画像を正規化する変換を作成
transform = v2.Compose([
    v2.ToTensor(),
    v2.Normalize(mean=[0.485, 0.456, 0.406], std=[0.229,
0.224, 0.225])
])
...
```

以下のコードを踏まえて、設問に答えよ。

```
...

# 画像に変換を適用
input_tensor = transform(rgb_img)
input_tensor = input_tensor.unsqueeze(0) # バッチの次元を追加

# CAMオブジェクトを構築
cam = GradCAM(model=model, target_layer=target_layer, use_cuda=True)

# target_categoryがNoneの場合、バッチ内の各画像に対して最もスコアの高いカテゴリが使用されま
す。
# target_categoryは整数でも、バッチ内の各画像に対して異なる整数のリストでも構いません。
target_category = [ClassifierOutputTarget(281)] #猫

grayscale_cam = cam(input_tensor=input_tensor, target_category=target_category)

# grayscale_camはバッチ内で1つの画像
grayscale_cam = grayscale_cam[0, :]
visualization = show_cam_on_image(rgb_img, grayscale_cam)

plt.imshow(visualization, vmin=0, vmax=255, interpolation='none')
plt.show()
```

コード1 Grad-CAM

以下のコードを踏まえて、設問に答えよ。



図1 : Grad-CAM出力結果
(出典 : <https://arxiv.org/pdf/1610.02391.pdf>)

```
VGG(
  (features): Sequential(
    (0): Conv2d(3, 64, kernel_size=(3, 3), stride=(1, 1), padding=(1, 1))
    (1): ReLU(inplace=True)
    (2): Conv2d(64, 64, kernel_size=(3, 3), stride=(1, 1), padding=(1, 1))
    (3): ReLU(inplace=True)
    (4): MaxPool2d(kernel_size=2, stride=2, padding=0, dilation=1, ceil_mode=False)
    ... (省略) ...
    (26): Conv2d(512, 512, kernel_size=(3, 3), stride=(1, 1), padding=(1, 1))
    (27): ReLU(inplace=True)
    (28): Conv2d(512, 512, kernel_size=(3, 3), stride=(1, 1), padding=(1, 1))
    (29): ReLU(inplace=True)
    (30): MaxPool2d(kernel_size=2, stride=2, padding=0, dilation=1, ceil_mode=False)
  )
  (avgpool): AdaptiveAvgPool2d(output_size=(7, 7))
  (classifier): Sequential(
    (0): Linear(in_features=25088, out_features=4096, bias=True)
    (1): ReLU(inplace=True)
    (2): Dropout(p=0.5, inplace=False)
    (3): Linear(in_features=4096, out_features=4096, bias=True)
    (4): ReLU(inplace=True)
    (5): Dropout(p=0.5, inplace=False)
    (6): Linear(in_features=4096, out_features=1000, bias=True)
  )
)
```

図2 : VGG出力結果

✕ コード 1 のプログラム内の Grad-CAM を適用するVGG16モデルの層を指定する（ あ ） について、以下のうち最も妥当な選択肢を 1 つ選べ。 *0/1

- ☐ model.classifier[0]
- ☐ model.classifier[-1]
- ☐ model.features[-1]
- ☒ model.features[0]

✕

✓ 'ClassifierOutputTarget(281)' は猫である。Grad-CAM の出力結果として、図 1 が得られた。このヒートマップが赤くなっている部分から考察できることとして、以下のうち正しい選択肢を 1 つ選べ。 *1/1

- ☒ 赤くなっている部分は、モデルが特定のクラスを識別する際に最も重要と判断した画像領域を示している。 ✓
- ☐ 赤くなっている部分は、モデルが予測の不確実性が高いと判断した領域を示している。
- ☐ 赤くなっている部分は、画像の品質が低いことを示しており、モデルの予測精度に影響を与えている。
- ☐ 赤くなっている部分は、モデルがそのクラスの予測に関与していないと判断した領域を示している。

XAIはExplainable AI（説明可能なAI）のことで、AIが導き出した結果の背景にある理由（プロセス）を明らかにしようとする取り組みやそのモデルのことである。XAIの技術として、代表的なものにGrad-CAM、（ あ ）、（ い ） などがある。

Grad-CAMとは、クラス分類予測をしたときに、モデルが重要視した箇所を可視化する技術で、CAMの技術を汎用化したものである。



- ✓ (あ) とは、モデルの結果を可読表現（説明可能表現）を介して説明として提示する手法である。精度を犠牲にせずに解釈性を高めることができ、適用するためにモデル自体に手を加える必要がなく、あらゆるモデルに適用できる点が特徴となる。 *1/1

(あ) に当てはまる選択肢について、以下から1つ選べ。

- ☐ SHAP
- ☒ LIME
- ☐ MAML
- ☐ Grad-CAM



- ✓ (い) とは、(あ) と同様の設計思想ながら、モデルの予測結果に対する各変数（特徴量）の寄与（重要度）を求めることで、より人間の納得がいく結果が得られやすくなった。 *1/1

(い) に当てはまる選択肢について、以下から1つ選べ。

- ☐ MAML
- ☐ LIME
- ☐ Grad-CAM
- ☒ SHAP



✓ 機械学習モデルの解釈を行うにあたって、主な解釈方法に大域的解釈と局所的解釈がある。機械学習モデルにおけるそれぞれの解釈方法に関する次の記述のうち、誤っているものを1つ選べ。 *1/1

- ☐ 局所的な解釈は個々の予測の背後にある理由を明らかにし、モデルが複雑である場合や個々の予測に特に関心がある場合に有用である。
- ☒ 大域的解釈は、1件の入力に対する予測だけを対象とし、その予測に対する各特徴量の寄与のみを説明する。 ✓
- ☐ 局所的な解釈はモデルが個々のデータポイントに対してどのような予測を行ったかを詳細に解析し、その予測に対する特定の特徴の影響を理解することを目的とする。
- ☐ 大域的解釈はモデル全体の動作を理解することを目的とし、モデルの信頼性やバイアスの特定、改善方向の理解に有効である。

✓ 機械学習やニューラルネットワークの社会利用が広がる一方で、モデルの予測根拠を人間が理解しにくいことが問題として指摘されている。 *1/1

2016年にデータ分析の国際会議「KDD」で、ワシントン大学の研究チームから発表された説明可能AIの手法として（ あ ）が挙げられる。（ あ ）は、複雑なモデルによる個々の予測を局所的に説明するため、説明対象となる入力の近傍に新たなデータサンプルを生成し、元のモデルによる予測結果を基に、解釈可能な（ い ）を学習する。

（ あ ）に当てはまる選択肢について、以下から1つ選べ。

- ☐ SHAP
- ☐ XAI
- ☐ CTC
- ☒ LIME ✓

✓ (い) に当てはまる選択肢について、以下から1つ選べ。 *

1/1

- ☐ k-meansクラスタリング
- ☒ 疎な線形モデル
- ☐ 畳み込みニューラルネットワーク
- ☐ 深層ニューラルネットワーク



✓ モデルの予測結果に対する各変数（特徴量）の寄与（重要度）を求める手法の1つとして、LIMEと同様の設計思想で作られたSHAPがある。SHAPの分析における主要な特徴に関する次の記述のうち、誤っているものを1つ選べ。 *1/1

- ☐ 局所的精度では、特徴量の寄与度と基準値の合計が、説明対象となる元モデルの出力と一致することが求められる。
- ☐ 欠落性では、簡略化された入力に存在しない特徴量へ寄与度0を割り当てる。
- ☐ 一貫性では、モデルの変更によって特徴量の貢献が増えた場合、その特徴量の寄与度が減少しないことが求められる。
- ☒ SHAPでは、すべての特徴量へ均等な重要度を割り当てることが求められる。



SHAPとは、2017年にNIPSでワシントン州立大学シアトル校を中心とした研究チームから発表された解釈可能化手法である。基本的にLIMEと同様の設計思想で作られており、利用する説明モデルも同じ線形モデルであるが、SHAPはより理想的な説明への要請に基づいた説明法である。

SHAPが説明可能なモデルとして掲げている理想的な要請は3つある。

1つ目は（ あ ）で、特定の入力 x のもとのモデル f を近似する場合、局所精度では、説明モデルの出力が一致する必要がある。

2つ目は（ い ）で、欠落した特徴量が結果に影響を与えないようにする必要がある。

3つめは（ う ）で、モデルが変更されて、ある特徴量 z' の有無で f' の値が f よりも大きく変わるのであれば、 f' におけるある特徴量 z' の貢献度は f よりも大きくなる必要がある。

✓ （ あ ）に当てはまる選択肢について、以下から1つ選べ。 * 1/1

- ☐ Linear（線形性）
- ☒ Local accuracy（局所的精度）
- ☐ Missingness（欠落性）
- ☐ Consistency（一貫性）



✓ （ い ）に当てはまる選択肢について、以下から1つ選べ。 * 1/1

- ☐ Consistency（一貫性）
- ☐ Linear（線形性）
- ☐ Local accuracy（局所的精度）
- ☒ Missingness（欠落性）



✓ (う) に当てはまる選択肢について、以下から1つ選べ。 *

1/1

- ☐ Missingness (欠落性)
- ☒ Consistency (一貫性)
- ☐ Linear (線形性)
- ☐ Local accuracy (局所的精度)



このフォームは デロイト トーマツ ディープスクエア株式会社 内部で作成されました。
このフォームが不審だと思われる場合 [報告](#)

Google フォーム



