





数学的基礎

2025年11月1日 改訂版

DeepSquare AI講座 AIエンジニア育成講座（E資格講座）

確率統計

- 確率・統計



✓ 確率モデルにおけるパラメータ推定

- 情報理論

確率モデルにおけるパラメータ推定

目標

- 機械学習を支える確率論に関する基本事項を理解する。
- 確率分布に基づいたモデルを構築し、観測されたデータに基づきそのパラメータを推定することができる。

キーワード

- ベイズ則
- ナイーブベイズ
- 平均二乗誤差
- 対数尤度
- ダイバージェンス
- 最尤推定
- MAP推定
- ベイズ推定


ポイント

- 確率の乗法定理を理解し、ベイズ則を導出できる。
- 尤度と事前確率から事後確率が推定できることを説明できる。
- 最尤推定とベイズ推定、MAP推定の違いを説明できる。
- 具体的例が与えられた際に統計モデルを構築し、ベイズ推定などを用いた推定を行う際の式展開ができる。

確率モデルにおけるパラメータ推定

頻度論とベイズ理論


- 従来の統計学は、一般に「**頻度論**」と呼ばれるアプローチに基づいている。
- 頻度論は製品管理や実験分析などの分野で重要な役割を果たしてきた。
- しかし、時間の異なるデータを活用する場合や、データ量が少ない場合の分析、また経験や事前確率を取り入れたデータ分析には、**ベイズ理論**がより適している場合が多いとされている。



確率モデルにおけるパラメータ推定

推論の目的：データから「モデル」を導き出す

確率モデルは、不確実性を伴う現象を数学的な枠組みで表現する。
観測データから「その背後にある法則（パラメータ）」を推定することが目的である。



1

限られたデータから出発

全ての現象を観測することはできず、サンプルから推測する必要がある。

2

最もよく説明する法則を見つける

観測データに当てはまる確率分布とそのパラメータを見つける。

3

未知の事象を予測可能にする

構築したモデルで、まだ起きていない事象の確率を評価できる。


確率モデルにおけるパラメータ推定

頻度論とベイズ理論

頻度論では、確率を「**同一条件のもとで試行を無限回繰り返したときに得られる相対頻度の極限**」として捉える。
ベイズ論では、確率を「**事象に対する確信度**」として捉える。

頻度論

(従来の統計学)



「確率は長期的な頻度である」

- ・ 事前確率は使わず、手元のデータのみを信じる。
- ・ 試行回数が無限であれば正確になる。
- ・ 製品管理や実験分析など、大量データを前提とする場面向いている。

ベイズ理論

(推測統計)




「確率は信念（確からしさ）の度合いである」

- ・ 事前確率を設定し、データで更新する。
- ・ データが少なくても推論可能。
- ・ 逐次的にデータを取り込めるため、ストリーム型の問題に強い。

確率モデルにおけるパラメータ推定

同時確率と条件付き確率



同時確率 (Joint Probability)

条件 A と B が同時に成り立つ（同時に Yes となる）確率。
ベン図の青い交差部分（Intersection）。

$$P(A, B)$$

条件付き確率 (Conditional Probability)

条件 A が成り立つときに、条件 B が成り立つ確率。
「A ならば B が起きる確からしさ」。

$$P(B|A)$$

$$P(A, B) = P(B|A) \cdot P(A) = P(A|B) \cdot P(B)$$

同時確率は「片方が起きる確率」×「その条件のもとでもう片方が起きる確率」に分解できる。

確率モデルにおけるパラメータ推定

ベイズ則

ベイズ則は条件付き確率に関して成り立つ定理であり、トーマス・ベイズによって提唱された。直接観測できない要素を含む状況での推論に広く用いられる。

$$\overset{\text{事後確率}}{P(A|B)} = \frac{\overset{\text{尤度}}{P(B|A)} \cdot \overset{\text{事前確率}}{P(A)}}{\underset{\text{エビデンス (正規化係数)}}{P(B)}}$$

$P(A|B)$

B が成り立つときに A が成り立つ確率（事後確率）

$P(B|A)$

A が成り立つときに B が成り立つ確率（尤度）

$P(A)$

A が成り立つ確率（事前確率）

$P(B)$

B が成り立つ確率（エビデンス・全体を 1 にする正規化）

確率モデルにおけるパラメータ推定

ベイズ則の直感的な理解

人は最初から何らかの思い込みを持ち、観測データによってその思い込みを現実に近いものへと修正する。
ベイズ則はこの営みを数学的に定式化したものである。




例：「雨が降る確率は50%」と思っていた → 空が暗くなっているのを見る → 「やっぱり雨が降る確率は80%かも」へ更新。

確率モデルにおけるパラメータ推定

ベイズ則の構成


ベイズ則を構成する4つの項を、それぞれの役割で整理する。
パラメータ θ と観測データ X の関係で書き換えたのが実用形。



確率モデルにおけるパラメータ推定

コインスのジレンマ

【 状況 】 コインが「公平」か「偏っている」か不明。表が出る確率 θ を推定したい。



事前確率 (Prior) : 50% / 50% で公平だと思っている

観測データ (Data) : 10回投げて、8回「表」が出た

このデータを見た後、3つの手法（MLE・MAP・ベイズ）はそれぞれどう結論を出すか？

確率モデルにおけるパラメータ推定

手法1：最尤推定（MLE）


「手元のデータがすべて」

尤度（観測データが得られる確率）が最大となる単一のパラメータを探索する手法。事前確率は一切使わない。

$$\theta_{ML} = \operatorname{argmax} \ln p(X|\theta)$$

結論

10 回中 8 回表が出たなら、「表が出る確率 = 80% のコインである」と一点張りで結論づける。



確率モデルにおけるパラメータ推定

対数尤度とMSE

対数尤度

- 尤度の対数を取ったもの。
- 観測データが得られる確率（尤度）は積の形で表されるが、対数を取ることで和に変換でき、計算が容易になる。
- 尤度関数の対数を取ったものを**対数尤度関数**という。

MSE (Mean Squared Error : 平均二乗誤差)

- 真の値と予測値との差を二乗した平均を取る。
- 外れ値の影響を受けやすいため、大きな誤差を許容できないケースに使用される。
- 回帰問題で最も標準的な損失関数として用いられる。

$$\text{MSE} = \frac{1}{m} \sum_{i=1}^m (y_i - \hat{y}_i)^2$$

m : データの個数
 y_i : 真の値
 $\hat{y}_i$: 予測値

確率モデルにおけるパラメータ推定

尤度関数と最尤推定量

複数の独立なデータから尤度を立て、それを最大化するパラメータを求める。
積は計算しにくいので対数を取って和にするのが定石である。

STEP 1 : 尤度関数を立てる

n 個の観測値 $x_1, x_2, \dots, x_n$ が互いに独立同分布で、確率（密度）関数 $f(x; \theta)$ に従うとする。
このとき尤度関数は各点の確率（密度）の積である。

$$L(\theta) = \prod_{i=1}^n f(x_i; \theta)$$

STEP 2 : 対数を取って和に変換

積のままでは扱いにくいので、単調増加関数である $\log$ を取る。
最大化問題の答えは変わらず、数値的にも安定する。

$$\ln L(\theta) = \sum_{i=1}^n \ln f(x_i; \theta)$$

STEP 3 : 対数尤度を最大化


パラメータ θ で偏微分して 0 となる点を求める。
この解が最尤推定量となる。

$$\theta_{\text{ML}} = \operatorname{argmax} \ln L(\theta)$$

確率モデルにおけるパラメータ推定

尤度計算の例：どちらの分布がデータに近い？

同じデータに対して、異なるパラメータの正規分布 A と B で尤度を比べる。
尤度はそれぞれのデータ点での確率密度の積で算出できる。



B の方が尤度が大きい → B の方がよりデータに当てはまる分布。このように尤度を最大化するパラメータを推定する方法を**最尤推定**と呼ぶ。

確率モデルにおけるパラメータ推定

手法 2 : MAP推定


「データ + 事前確率の妥協点」

事後確率を最大にする単一のパラメータを求める。
無情報事前分布でない場合、事前確率がデータにペナルティを与える。

$$\theta_{\text{MAP}} = \operatorname{argmax} P(X|\theta) \cdot P(\theta)$$

結論

データは80%を示しているが、事前の「公平（50%）」という信念に引っ張られ、「表の確率は65%くらい」と一点張りで結論づける。



確率モデルにおけるパラメータ推定

MAP 推定の式展開

MAP (Maximum A Posteriori) 推定は事後確率 $P(\theta|X)$ を最大化する。
対数を取ることで、最尤推定の式に事前分布の項を加えた形になる。

事後確率を最大化するパラメータを探す

$$\theta_{\text{MAP}} = \operatorname{argmax} P(\theta|X)$$

ベイズ則で書き換え

$$= \operatorname{argmax} \left[\frac{P(X|\theta) \cdot P(\theta)}{P(X)} \right]$$

$P(X)$ は θ に依存しないので無視できる

$$= \operatorname{argmax} [P(X|\theta) \cdot P(\theta)]$$

対数を取ると和に変換できる (単調変換なので解は同じ)

$$= \operatorname{argmax} [\ln P(X|\theta) + \ln P(\theta)]$$

**MAP推定は、最尤推定の式に「事前分布の対数」を足し合わせたもの。
事前分布がペナルティ項として働き、データが少ないときに推定を安定化させる。**

確率モデルにおけるパラメータ推定

MLE と MAP のつながり

対数で見ると、MAP推定は最尤推定の式に事前分布の項を足し合わせたものに過ぎず、どちらも「最も確率が高い1つの値」を求める点推定である。




共通点：どちらの手法も「点推定」

「最も確率が高い1つの値（argmax）」だけを探索・算出する点が共通している。
得られた1つの推定値だけを答えとするため、分布の広がり（不確実性）の情報は失われる。

確率モデルにおけるパラメータ推定

点推定で見落とされる情報

対象とする現象が複数のピークを持つ「多峰性」を示す場合、点推定（argmax）は1番高いピーク以外の重要な情報を完全に捨て去る。



⚠ 失われる情報

2番目のピーク、分布の裾の厚さ、不確実性の幅

➡ この限界を超えるのが...

ベイズ推定 → 分布の「形」そのものを推定することで、不確実性を捨てずに扱う。

確率モデルにおけるパラメータ推定

手法 3 : ベイズ推定


「不確実性を分布ごとと抱え込む」

argmax を用いて推定量の「一点」を求めるのではなく、パラメータがとる値の「分布（形状）」そのものを求める。

$$P(\theta|X) = P(X|\theta) \cdot P(\theta) / P(X)$$

結論


「表が出る確率は65%あたりが一番高そうだが、40～80%の間に収まる確率分布になっている」と、可能性の広がり（不確実性）を含めて結論づける。



確率モデルにおけるパラメータ推定

ベイズ推定の流れ：逐次学習のサイクル

ベイズ推定では、新しいデータが得られるたびに事後分布を計算し直すことができる。このとき、得られた事後分布をそのまま次の事前分布として用いることで、観測を重ねるごとに推定を更新していく「逐次学習」のサイクルが成り立つ。



逐次学習：今回の事後分布が、次回の事前分布になる

事前分布と尤度がともに正規分布のとき、事後分布も正規分布になる。


このように、事前分布と尤度の組合せによって事後分布が同じ分布族になる性質を「共役性」と呼び、共役な組合せを使えば更新の計算を簡潔に行える。

確率モデルにおけるパラメータ推定

アプローチの視覚的比較

3つの手法がそれぞれ「何を推定結果として返すか」を整理する。

MLEとMAPは一点を返すのに対し、ベイズ推定は分布そのものを返す点が本質的な違いである。



確率モデルにおけるパラメータ推定

MLE・MAP・ベイズ推定の比較

3手法の特徴を4つの観点から整理する。
データ量・事前確率の有無・計算コストに応じて、課題ごとに適した手法を選択できる。

比較項目	最尤推定 (MLE)	MAP 推定	ベイズ推定
出力形式	点推定	点推定	分布推定
事前確率の利用	なし	あり	あり
計算コスト	低	低 ~ 中	高
最大の強み	大量データで高効率	少量データを補完	不確実性の完全な把握
弱み	少量データで不安定	事前分布の選び方に依存	計算コストが高い

→ データが豊富ならMLE、データが少なく事前確率が活用できるならMAP、不確実性そのものを評価したいならベイズ推定。

確率モデルにおけるパラメータ推定

例題：工場の不良品率推定

問題

ある製造工場では、新しい製品ラインの不良率を把握するために検査を実施している。


事前知識として、過去の経験から「不良率はおよそ40%程度」と見込んでおり、これを事前分布として **Beta($\alpha=4$, $\beta=6$)** で表す。
観測データとして製品20個を検査した結果、不良品が7個、良品が13個であった。

→ 観測データを用いて事後分布を求め、不良率の事後期待値を推定せよ。

【 観測結果：20 個の検査 】

● 不良品 × 7

● 良品 × 13



確率モデルにおけるパラメータ推定

解答：ベイズ更新の計算

事前分布

$$\text{Beta}(\alpha = 4, \beta = 6)$$

事前期待値： $4 / (4+6) = 0.4$ （不良率 40% と想定）

観測データ

20 個中 7 個が不良品


→ この観測を元に事後分布へ更新

事後分布（更新後）

$$\begin{aligned} &\text{Beta}(\alpha + x, \beta + (n - x)) \\ &= \text{Beta}(4 + 7, 6 + 13) = \text{Beta}(11, 19) \end{aligned}$$

事後期待値

$$11 / (11 + 19) \div 0.367 \text{ (約36.7\%)}$$



予測が40%から36.7%へ修正され、確信度（山の鋭さ）が増した。
観測データに応じて分布を更新することで、より信頼できる推定値が得られる。

情報理論

- 確率・統計
- 情報理論



✓ 情報理論

目標

- 情報の定量的尺度であるエントロピーと相互情報量を理解する。

キーワード

- 自己情報量
- 相互情報量
- エントロピー
- 条件付きエントロピー
- 結合エントロピー
- クロスエントロピー
- KLダイバージェンス
- JSダイバージェンス

ポイント

- キーワード項目の数式的な理解に加え、クロスエントロピーとKLダイバージェンスの密接な関係性や、KLダイバージェンスの非対称性を理解し、機械学習分野での使い方を説明できる。
- キーワード項目の数式的な理解をし、異なる確率分布のお互いの依存度を説明できる。

情報理論

情報量（自己情報量、自己エントロピー、選択情報量）

- あるできごと（事象）が起きた際、それがどれほど起こりにくいかを表す尺度。

情報量 I の計算式

事象 x が起こる確率 $P(x)$ のとき、

$$I(X) = -\log P(x)$$


$P(x)$ は 0~1 の範囲を取るため、 $-\log P(x)$ は、

$P(x) = 0$ の時 $\rightarrow \infty$

$P(x) = 1$ の時 $\rightarrow 0$

$\Rightarrow$ 起こりにくい事象ほど、情報量が多くなる。

※ 起こりにくい事象ほど情報の価値が高い、ともイメージできる。



相互情報量

- 2つの情報量が互いにどれだけ影響し合っているかを示す尺度。
- 各事象の確率の積と結合確率の商の自己情報量の期待値で定義される。

- $I(X; Y) = E p_{(x, y)} \left[-\log_2 \frac{P(x)P(y)}{P(x, y)} \right]$

$$= -\sum_x \sum_y P(x, y) \log_2 \frac{P(x)P(y)}{P(x, y)}$$

$$= \sum_x \sum_y P(x, y) \log_2 \frac{P(x, y)}{P(x)P(y)}$$

- 2つの事象間に依存関係がないとき、 $\frac{P(x, y)}{P(x)P(y)} = 1$ となり、 $\log_2 1 = 0$ より、 $I(X; Y)$ は最小値**0**をとる。

エントロピー（平均情報量、シャノンエントロピー）

- ・ 情報量を平均化したもの。
- ・ 確率分布の「複雑さ（予測のしにくさ）」を表す指標。


エントロピー $H(x)$ の計算式

事象 x が起こる確率を $P(x)$ とすると、

$$H(X) = - \sum_{i=1}^n P(x_i) \log P(x_i)$$

対数の底と単位


底	通常の単位	JISおよびISOが定めた単位	備考
2	ビット (bit)	シャノン (shannon)	lb, 二進対数
$e=2.718\cdots$	ナット (nat)	ナット (nat)	ln, 自然対数
10	ディット (dit)	ハートレー (hartley)	lg, 常用対数



情報量の**対数の底**は、
2（ビット、シャノン）が多い
⇒ コンピュータは、0,1の2値で制御されているため

「確率分布の複雑さ」のイメージ

- 正規分布において、平均が同じで、分散が異なるグラフを以下のように表現できる。



分散が大きなグラフの方が、ばらつきが大きい = 予測がしにくい。
⇒ **分散が大きいほどエントロピーが大きい。**

クロスエントロピー（交差エントロピー）

- 2つの確率分布の異なりを表す指標。
- 1つの確率分布を $P(x)$ 、もう一方を $Q(x)$ とすると以下で表すことができる。

$$H = -P(x) \log Q(x)$$

クロスエントロピーの解釈

- 予測結果の情報量を正解の分布の重みで平均化していると解釈することもできる。
- 正解の分布と予測結果の分布が異なるほど、交差エントロピーの値は大きくなる。

条件付きエントロピー

- Y について既に知っている状態から X について新たに知ったときに得られる情報量の期待値。

- $H(X|Y) = \mathbb{E}_{p_{(x,y)}}[I(y|x)]$


$$= \sum_x \sum_y P(x, y) I(y|x)$$

$$= -\sum_x \sum_y P(x, y) \log_2 P(x|y)$$

- また、エントロピーと条件付きエントロピーの差は相互情報量となる。

$$\text{すなわち、} H(X) - H(X|Y) = I(X; Y)$$

を満たす。



結合エントロピー


- X と Y をまとめて1つのものとしたときのエントロピー
- $H(X, Y) = H(X) + H(Y) - I(X; Y)$

$$\begin{aligned} &= -\sum_x P(x) \log P(x) - \sum_y P(y) \log P(y) - \sum_x \sum_y P(x, y) \log_2 \frac{P(x, y)}{P(x)P(y)} \\ &= -\sum_x \sum_y P(x, y) \log_2 P(x, y) \end{aligned}$$

- 2つの確率分布が独立している場合、

$$H(X, Y) = H(X) + H(Y)$$

を満たす。



KL（カルバック – ライブラー）ダイバージェンス（相対エントロピー）

- モデルの分布 $q(x)$ が真の分布 $p(x)$ とどれだけ異なっているかを表す指標。モデルの性能がわかる。
（値が大きいほど、2つの分布が異なっていることになる。）
- KLダイバージェンスが最小になるような $q(x)$ を求めることが目標。

$D_{KL}(p||q)$: KLダイバージェンス、 $p(x)$: 真の分布、 $q(x)$: モデルの分布

$$D_{KL}(p||q) = \int p(x) \log \frac{p(x)}{q(x)} dx$$

$$= \int p(x) \log p(x) dx - \left(\int p(x) \log q(x) dx \right)$$

エントロピー

交差エントロピー

= この値が大きいほど、KLダイバージェンス全体の値は小さくなる。



2つの確率分布を情報量に変換して、その差を見ている。

KLダイバージェンスの性質

$$D_{KL}(p||q) \geq 0$$

$$p(x) = q(x) \text{ のとき、} D_{KL}(p||q) = 0$$

$$D_{KL}(p||q) \neq D_{KL}(q||p)$$



同じ確率分布の時、KLダイバージェンスの値は0

確率分布 p, q から求めた場合と、 q, p から求めた場合では異なる値となる。
そのため、距離と表現せず、ダイバージェンスと呼ばれる。（対称性が無い。）

JS (ジェンセン・シャノン) ダイバージェンス

- KLダイバージェンスは、 $D_{KL}(p||q)$ と $D_{KL}(q||p)$ の対称性がないため、距離として扱うことができない。
- そこで、提案されたのがJensen-Shannon ダイバージェンスである。
- Jensen-Shannon ダイバージェンス の $D_{JS}(p||q)$ と $D_{JS}(q||p)$ は同じ計算結果になり対称性がある。
- KL ダイバージェンスを平滑化+対称性を持たせたものが、JS ダイバージェンスとも言われる。

$$D_{JS}(p||q) = \frac{1}{2} D_{KL}(p||m) + \frac{1}{2} D_{KL}(q||m)$$

- 情報量の式 : $I = -\log P(x)$
- 相互情報量の式 : $I(X; Y) = \sum_x \sum_y P(x, y) \log_2 \frac{P(x, y)}{P(x)P(y)}$
- エントロピーの式 : $H(X) = -\sum_x P(x) \log P(x)$
- クロスエントロピーの式 : $H = -\sum_x P(x) \log Q(x)$
- 条件付きエントロピーの式 : $H(X|Y) = -\sum_x \sum_y P(x, y) \log_2 P(x|y)$
- 結合エントロピーの式 : $H(X, Y) = -\sum_x \sum_y P(x, y) \log_2 P(x, y)$
- KLダイバージェンスの式 : $D_{KL}(p||q) = \int p(x) \log p(x) dx - \int p(x) \log q(x) dx$
- JSダイバージェンスの式 : $D_{JS}(p||q) = \frac{1}{2} D_{KL}(p||m) + \frac{1}{2} D_{KL}(q||m)$